

DATE DE DÉPÔT : 04/04/2025

Minh Anh NGUYEN

Hoang Ngoc Lam LE

Université de Lille – BUT SD – Semestre 4 -2024/2025

SAÉ 4.EMS.01

**Expliquer ou prédire une variable quantitative
à partir de plusieurs facteurs**

TD2 - BUT2

SAÉ 4.EMS.01

Expliquer ou prédire une variable quantitative à partir de plusieurs facteurs

Compétences ciblées

- Modéliser les données dans un cadre statistique
- Analyser statistiquement les données
- Valoriser une production dans un contexte professionnel

Objectifs et problématique professionnelle

De nombreuses études cherchent à expliquer, à l'aide d'un modèle, les variations statistiques d'une variable quantitative en fonction de plusieurs variables explicatives. La modélisation linéaire, qui consiste à expliquer linéairement la variable d'intérêt par rapport aux autres variables, dites explicatives est utilisée en entreprise et dans les organisations. En effet, elles ont souvent pour besoin de trouver le modèle le plus adéquat, parmi une sélection de modèles, selon le but recherché : obtenir un modèle à fort potentiel prédictif, ou obtenir le modèle le plus parcimonieux possible.

En tant que statisticien, vous serez amenés à mettre en place un modèle linéaire multivarié à partir d'un échantillon d'individus, pour expliquer les variations d'une variable quantitative à partir de plusieurs variables explicatives qualitatives ou quantitatives.

Les objectifs de cette SAÉ sont les suivants :

- prendre conscience de l'importance de préparer les données pour une modélisation statistique ;
- identifier différents modèles en vue de sélectionner le plus pertinent ;
- réaliser toutes les étapes amenant à la modélisation.

Descriptif générique

Vous serez mis en situation de comparaison de plusieurs groupes de variables et de modélisation du lien entre des variables afin d'expliquer une variable d'intérêt, notamment pour en effectuer sa prévision.

Cette SAE a pour but de mettre en œuvre des outils statistiques permettant de décrire et d'explorer les relations linéaires entre les variables, en insistant sur la compréhension des modèles statistiques impliqués et l'évaluation de leur qualité.

Vous devez donc mettre en œuvre une modélisation, en traitant des données sur lesquelles vous appliquerez un modèle linéaire multivarié.

Au cours de l'analyse, vous devrez effectuer les étapes suivantes : choisir le modèle adapté aux types des variables, ajuster un modèle de régression linéaire aux données, calculer les estimateurs et interpréter les résultats, tester le caractère significatif des paramètres estimés, repérer et traiter les points aberrants et les données influentes, valider le modèle, notamment via l'étude des résidus et l'interprétation de certains coefficients, sélectionner les variables explicatives les plus pertinentes, comparer différents modèles et effectuer des prévisions.

Présentation du sujet et problématique

Vous disposez de 3 fichiers :

- Salaires joueurs NBA : Feuille de calcul Microsoft Excel (.xlsx)
- Statistiques joueurs NBA : Feuille de calcul Microsoft Excel (.xlsx)
- Explication des statistiques affichées : Document Microsoft Word (.docx)

Ces 3 fichiers contiennent un certain nombre d'informations sur les joueurs de la NBA, leurs performances, équipes, salaires...

Table des matières

Première partie	4
1) Découverte de la NBA.....	4
L'histoire de la NBA	4
Quelle équipe a remporté le plus de titres NBA ?	4
Quel joueur a remporté le plus de titres NBA ?	5
Quel joueur a remporté le plus de titres MVP ?	5
Les règles du jeu NBA.....	5
Le format de la compétition NBA	6
La hausse des salaires NBA depuis 20 ans.....	6
2) Découverte et description des données.....	6
Des règles du basketball en NBA	6
Explications de toutes les variables	9
Deuxième partie.....	10
1) Travail sur les fichiers et les données	10
Nettoyage des données des fichiers Salaires joueurs NBA.xlsx et Statistiques joueurs NBA.xlsx	10
2) Analyse Statistique des Performances des Joueurs et Commentaire	12
a. Variable Quantitative	12
Introduction	12
Commentaire des statistiques des variables.....	12
Conclusion Générale.....	17
b. Variable Qualitative.....	18
Troisième partie : Modèles de régression linéaire simple	19
1. Choisir les variables pour le modèle	19
2. Régression linéaire simple	20
2.1 Le salaire en fonction de PTS (points)	20
2.2 Le salaire en fonction de FGM (nombre moyen de tirs réussis par match).....	24
3. Conclusion.....	28
Problème d'hétéroscédasticité.....	28
Problème de non-normalité des résidus.....	28
Problème de présence des observations atypiques	29
Conclusion générale	29
4. Changement du Salaire pour stabiliser la variance	30
4.1 Le $\sqrt{\text{salaire}}$ en fonction de FP (Fantasy Points)	31
4.2 Le $\sqrt[3]{\text{salaire}}$ en fonction de FP (Fantasy Points).....	36

4.3 Conclusion	40
Quatrième partie : Modèles de régression linéaire avec deux variables.....	41
1. Choisir les variables pour le modèle	41
2. Régression linéaire deux variables.....	42
2.1 Le salaire en fonction de Age et PTS (points).....	42
2.2 Conclusion	47
3. Changement du Salaire pour stabiliser la variance	48
3.1 Le $\sqrt{\text{salaire}}$ en fonction de Age et FP (Fantasy Points).....	49
3.2 Conclusion	54
Cinquième partie : Modèles de régression linéaire avec plusieurs variables ..	55
1. Choisir les variables pour le modèle	55
2. Régression linéaire plusieurs variables	58
2.1 Le $\sqrt{\text{salaire}}$ en fonction de Age W (wins) FT_PERCENT((Free Throw Percentage) et PTS (points).....	58
Sixième partie : Prédire du salaire 5 joueurs réel à l'aide des modèles de régression linéaire	64
Modèle 1 variable : Salaire - PTS	64
Modèle 1 variable : Racine_Salaire - FP	64
Modèle 2 variables : Salaire – Age et PTS	64
Modèle 2 variables : Racine_Salaire – Age et FP.....	65
Modèle multiples variables : Racine_Salaire – Age et FP.....	65
Septième partie : Suppression des observations mal reconstituées.....	66

Première partie

1) Découverte de la NBA

La National Basketball Association (NBA) est la ligue de basketball la plus prestigieuse et la plus suivie en Amérique du Nord et dans le monde. Fondée en 1949 à la suite de la fusion de la Basketball Association of America (BAA) et de la National Basketball League (NBL), elle est aujourd'hui composée de 30 équipes, dont 29 aux États-Unis et 1 au Canada. La NBA est devenue une organisation majeure du sport mondial, avec des joueurs et des équipes de réputation internationale.

Logo :



L'histoire de la NBA

Le premier match NBA a eu lieu le 6 juin 1946, sous le nom de BBA. Trois ans plus tard, en 1949, la BBA fusionne avec la NBL pour créer la NBA telle que nous la connaissons aujourd'hui. Depuis sa création, la ligue n'a cessé de croître et de se diversifier. En 1976, la American Basketball Association (ABA) a également rejoint la NBA, augmentant ainsi le nombre d'équipes.

La NBA a profondément marqué l'histoire du sport, en accueillant des légendes du basketball telles que Michael Jordan, Kareem Abdul-Jabbar, et LeBron James, qui ont tous laissé une empreinte indélébile dans l'histoire du basketball mondial.

Quelle équipe a remporté le plus de titres NBA ?

Les Boston Celtics détiennent le plus grand nombre de titres NBA, avec 18 victoires. Ils sont suivis par les Los Angeles Lakers, qui en ont remporté 17, puis les Golden State Warriors avec 7 titres, les Chicago Bulls avec 6 et les San Antonio Spurs avec 5.

Photo des 30 équipes de NBA



Quel joueur a remporté le plus de titres NBA ?

Bill Russell est le joueur ayant remporté le plus de titres NBA, avec 11 victoires. Vient ensuite Sam Jones avec 10 titres. D'autres joueurs tels que Tom Heinsohn, K.C. Jones, Tom "Satch" Sanders et John Havlicek ont remporté 8 titres chacun.



Quel joueur a remporté le plus de titres MVP ?

Kareem Abdul-Jabbar détient le record du plus grand nombre de titres MVP, avec 6 distinctions. Michael Jordan et Bill Russell suivent avec 5 titres MVP chacun. Wilt Chamberlain et LeBron James ont chacun remporté 4 trophées MVP.

Les règles du jeu NBA

Les règles du jeu NBA ont évolué au fil du temps. Voici quelques-unes des règles importantes :

- **Durée du match** : Un match se compose de 4 quarts-temps de 12 minutes. En cas d'égalité à la fin du temps réglementaire, une prolongation de 5 minutes est accordée.
- **Position de hors-jeu** : Un joueur offensif ne peut pas toucher le ballon lorsqu'il se trouve dans la zone de hors-jeu (entre le milieu de terrain et la zone rectangulaire avant chaque panier). L'équipe adverse bénéficie alors d'un lancer de touche.
- **Fautes** : Chaque joueur peut commettre jusqu'à 6 fautes par match. Si un joueur commet 4 fautes dans un quart-temps, l'équipe adverse bénéficie de lancers francs.
- **Lancer franc** : Un lancer franc est accordé lorsqu'un joueur est fauté lors d'une tentative de tir ou pendant l'action de tir.
- **Remplacements** : Les remplacements peuvent être effectués lors des pauses, entre les quarts-temps ou après un panier marqué. Chaque équipe peut effectuer un maximum de 7 changements par match.
- **Tir à trois points** : Un tir réussi au-delà de la ligne des trois points rapporte 3 points.
- **Tir à deux points** : Un tir réussi à l'intérieur de la ligne des trois points rapporte 2 points.


Le format de la compétition NBA

La NBA divise ses équipes en deux conférences (Est et Ouest), chaque conférence étant composée de 3 divisions, chacune comptant 5 équipes. La saison est divisée en 3 phases :

- Pré-saison : La phase de préparation, où les équipes jouent des matchs amicaux.
- Saison régulière : La phase officielle, où les équipes s'affrontent selon un calendrier fixe. Les 8 meilleures équipes de chaque conférence accèdent aux séries éliminatoires.
- Playoffs : Les séries éliminatoires. 16 équipes (8 de chaque conférence) se disputent en élimination directe pour déterminer le champion de la saison.
-

La hausse des salaires NBA depuis 20 ans

Les salaires des joueurs NBA a connu des changements importants au cours des 20 dernières années. En 1993, le salaire moyen d'un joueur était de 1,09 million de dollars (soit l'équivalent de 1,8 million de dollars aujourd'hui en tenant compte de l'inflation). Cependant, ce montant a triplé en 2003 avant de se stabiliser. L'augmentation des salaires a commencé en 1995, lorsque Michael Jordan est revenu, permettant à des stars comme lui et Patrick Ewing de signer des contrats énormes. Par exemple, en 1998, Jordan a gagné 33,1 millions de dollars, ce qui équivaut à 46,3 millions de dollars aujourd'hui. Cependant, après le lockout de 1999, des règles plus strictes ont limité cette croissance. Néanmoins, certains propriétaires, comme Mikhail Prokhorov avec les Brooklyn Nets, continuent de dépenser massivement pour remporter des titres.



2) Découverte et description des données

Des règles du basketball en NBA

Un terrain de jeu, deux équipes, deux paniers et un ballon - le match peut commencer.

Joueurs


Au basket, ce sont dix joueurs qui occupent le terrain, donc cinq par équipe. Chaque équipe a le droit d'avoir jusqu'à sept remplaçants qui peuvent être envoyés sur le terrain autant de fois que nécessaire.

Durée des Matches

Un match de NBA se divise en quatre quarts-temps de 12 minutes chacun. Si le score est égal à la fin du temps réglementaire, une prolongation de 5 minutes est jouée. Les prolongations se succèdent jusqu'à ce qu'une équipe ait plus de points que l'autre à la fin d'une période supplémentaire

Les tirs

Lancer le ballon dans le panier de l'équipe adverse, panier placé à 3,05 m de haut au bord de la ligne la moins longue délimitant le terrain. Un lancer-franc rapporte un point, un tir normal deux points. Si joueur qui lance le ballon se situe derrière la ligne des trois points, le panier rapporte trois points




Vert : des tirs réussis

Rouge : des tirs tentés

Le Tir à Trois Points (3P)

La distance de la ligne à trois points est de 23,75 pieds (environ 7,24 mètres) de l'anneau, à l'exception des coins du terrain où elle est réduite à 22 pieds (environ 6,71 mètres).



Vert : des tirs à trois point réussis

Rouge : des tirs à trois points tentés

Rebonds et Gestion de la Possession

Un joueur récupère le ballon après un tir manqué, soit en attaque pour garder la possession, soit en défense pour empêcher l'adversaire de marquer. Ces actions sont essentielles pour contrôler le jeu et créer des opportunités.

La Faute en NBA

- Faute personnelle : Commise lorsqu'un joueur agit illégalement contre un adversaire. Après plusieurs fautes, un joueur peut être exclu.
- Faute défensive : Lors d'une tentative de tir adverse, cela donne des lancers francs à l'adversaire.
- Faute offensive : Commise lorsqu'un joueur charge un défenseur, offrant la possession au camp adverse.
- Bonus des lancers francs : Après un certain nombre de fautes collectives, l'adversaire reçoit des lancers francs, même sans tir.
- Faute technique : Comportement inapproprié envers les arbitres, entraînant un lancer franc pour l'adversaire.
- Faute flagrante : Faute violente ou dangereuse, menant à deux lancers francs et la possession pour l'équipe adverse.

Explications de toutes les variables

1 Variable qualitative

- **TEAM** : Équipe dans laquelle il joue.

27 variables quantitatives

- **AGE** : Âge du joueur.
- **GP** (Games Played) : Nombre de matchs joués.
- **W** (Wins) : Nombre de victoires.
- **L** (Losses) : Nombre de défaites.
- **MIN** (Minutes per game) : Nombre moyen de minutes jouées par match.
- **PTS** (Points per game) : Nombre moyen de points marqués par match.
- **FGM** (Field Goals Made) : Nombre moyen de tirs réussis par match.
- **FGA** (Field Goals Attempted) : Nombre moyen de tirs tentés par match.
- **FG%** (Field Goal Percentage) : Pourcentage de réussite aux tirs (% de tirs marqués par rapport aux tirs tentés). $FG\% = (FGM / FGA) \times 100$
- **3PM** (Three-Point Field Goals Made) : Nombre moyen de tirs à 3 points réussis par match.
- **3PA** (Three-Point Field Goals Attempted) : Nombre moyen de tirs à 3 points tentés par match.
- **3P%** (Three-Point Percentage) : Pourcentage de réussite aux tirs à 3 points. $3P\% = (3PM / 3PA) \times 100$
- **FTM** (Free Throws Made) : Nombre moyen de lancers francs réussis par match.
- **FTA** (Free Throws Attempted) : Nombre moyen de lancers francs tentés par match.
- **FT%** (Free Throw Percentage) : Pourcentage de réussite aux lancers francs. $FT\% = (FTM / FTA) \times 100$
- **OREB** (Offensive Rebounds) : Nombre moyen de rebonds offensifs par match.
- **DREB** (Defensive Rebounds) : Nombre moyen de rebonds défensifs par match.
- **REB** (Total Rebounds) : Nombre moyen total de rebonds par match. $REB = OREB + DREB$
- **AST** (Assists per game) : Nombre moyen de passes décisives par match.
- **TOV** (Turnovers per game) : Nombre moyen de balles perdues par match.
- **STL** (Steals per game) : Nombre moyen d'interceptions par match.
- **BLK** (Blocks per game) : Nombre moyen de contres par match.
- **PF** (Personal Fouls) : Nombre moyen de fautes personnelles commises par match.
- **FP** (Fantasy Points) : Points calculés selon un barème pour les ligues de fantasy basketball.
- **DD2** (Double-Doubles) : Nombre de matchs où le joueur a atteint au moins 10 dans deux catégories statistiques (ex : points et rebonds).
- **TD3** (Triple-Doubles) : Nombre de matchs où le joueur a atteint au moins 10 dans trois catégories statistiques (ex : points, rebonds et passes).
- **+/-** (Plus/Minus) : Différence de points quand le joueur est sur le terrain (positif = son équipe marque plus de points que l'adversaire quand il joue, négatif = son équipe encaisse plus de points).

Deuxième partie

1) Travail sur les fichiers et les données

Nettoyage des données des fichiers Salaires joueurs NBA.xlsx et Statistiques joueurs NBA.xlsx

Afin d'assurer une fusion correcte des données entre ces deux fichiers, nous avons appliqué plusieurs étapes de nettoyage et de standardisation.

Pour préserver les données originales, nous avons créé une copie des feuilles de calcul dans chaque fichier avant d'effectuer les modifications, permettant ainsi de vérifier et comparer les données initiales à tout moment.

1. Préparation du fichier Salaires joueurs NBA.xlsx

Nous avons sélectionné uniquement les colonnes pertinentes, à savoir le nom du joueur et son salaire pour la saison 2024-2025, en supprimant toutes les autres informations relatives aux saisons précédentes ou futures.

Afin d'assurer une meilleure gestion des données et d'éviter tout problème de traitement, nous avons renommé la colonne "2024/2025" en "salaire" et procédé à un nettoyage de son format :

- Nous avons utilisé la fonction =SUBSTITUE (cellule_salaire ;",";"") pour supprimer les virgules.
- Ensuite, nous avons appliqué =SUBSTITUE (cellule_salaire ;"\$";"") pour retirer le symbole "\$" au début de chaque valeur.
- Enfin, nous avons converti la colonne en format numérique (nombre) dans Excel.

Toutefois, après l'importation du fichier dans SAS, nous avons vérifié la table avec PROC CONTENTS, et nous avons constaté que la colonne salaire était toujours au format texte (char). Pour corriger cela, nous avons effectué la conversion directement dans SAS avec la commande suivante :

```
DATA work.TAB_Player_CLEAN ;  
SET work.TAB_Player ;  
SALAIRE_NUM = INPUT (Salaire, COMMA12.) ;  
DROP Salaire ;  
RENAME SALAIRE_NUM = Salaire ;  
RUN ;
```

Cette étape garantit que les valeurs de salaire sont bien traitées comme des nombres, facilitant ainsi les analyses et les calculs ultérieurs.

2. Préparation du fichier Statistiques joueurs NBA.xlsx

Nous avons supprimé tous les liens présents dans les colonnes pour éviter d'éventuelles erreurs lors de la mise en correspondance des données.

Nous avons modifié le format des colonnes contenant des statistiques (comme les points) en convertissant les nombres du format 1.0 en 1,0, afin de les enregistrer en format numérique plutôt qu'en texte (caractère). Cette modification a été appliquée aux colonnes allant de **Min** à +/-.

Nous avons renommé la colonne +/- en **Plus_minus** pour éviter toute ambiguïté et améliorer la lisibilité des données.

Ensuite, nous avons comparé les noms et prénoms des joueurs entre les deux fichiers afin de détecter d'éventuelles incohérences.

3. Problèmes rencontrés lors de l'appariement des noms

Lors de la fusion des fichiers, plusieurs incohérences dans l'écriture des noms ont entraîné des erreurs d'appariement. Les problèmes principaux identifiés sont les suivants :

- Présence de suffixes tels que Jr., II, III et IV qui différaient d'un fichier à l'autre.
- Utilisation d'accents et de caractères spéciaux dans un fichier mais pas dans l'autre (É, ç, ô, Š, í, etc.).
- Variations dans l'écriture des prénoms et noms, par exemple :
"Nic" vs "Nicolas"
"Patty" vs "Patrick"
"Josh" vs "Joshua"
- Espaces et ponctuations superflues affectant la correspondance des noms.
- Présence de points dans les prénoms abrégés, par exemple : "P.J. Washington" était écrit sous la forme "PJ Washington".

4. Modifications et corrections apportées

Pour garantir une correspondance correcte entre les fichiers, nous avons effectué les actions suivantes :

- Suppression des suffixes (Jr., II, III, IV) dans les noms des joueurs des deux fichiers.
- Standardisation des caractères en supprimant les accents et caractères spéciaux :
 $\text{É} \rightarrow \text{E}$, $\text{Ç} \rightarrow \text{C}$, $\text{Š} \rightarrow \text{S}$, $\text{č} \rightarrow \text{c}$, etc.
- Harmonisation des prénoms selon des règles de normalisation :
"Nic Claxton" a été remplacé par "Nicolas Claxton".
"Patty Mills" a été remplacé par "Patrick Mills".
"Josh Primo" a été remplacé par "Joshua Primo".
- D'autres diminutifs ont été ajustés en fonction des joueurs concernés.
- Suppression des points dans les prénoms abrégés, par exemple :
"P.J. Washington" $\rightarrow$ "PJ Washington".
- Élimination des espaces et caractères superflus :
Suppression des espaces en début et fin de texte.
Retrait de toute ponctuation non essentielle.

Grâce à ces étapes de nettoyage et de normalisation, la fusion des données entre les fichiers Salaires joueurs NBA.xlsx et Statistiques joueurs NBA.xlsx a été réalisée avec une meilleure précision, réduisant considérablement les erreurs d'appariement.

2) Analyse Statistique des Performances des Joueurs et Commentaire

a. Variable Quantitative

Variable	Libellé	N	Moyenne	Médiane	Ecart-type	Minimum	Maximum	Intervalle	Quartile inférieur	Quartile supérieur
Salair		450	11015054.30	5250000.00	12774054.78	100000.00	55761217.00	55661217.00	2237691.00	14318182.00
Classement	Classement	450	248.3866667	231.5000000	157.4593434	1.0000000	563.0000000	562.0000000	113.0000000	373.0000000
Age	Age	450	26.0622222	25.0000000	4.3067921	19.0000000	39.0000000	20.0000000	23.0000000	28.0000000
GP	GP	450	52.4511111	58.0000000	23.2999911	1.0000000	84.0000000	83.0000000	37.0000000	72.0000000
W	W	450	26.7444444	27.0000000	15.7670692	0	64.0000000	64.0000000	13.0000000	40.0000000
L	L	450	25.7066667	25.0000000	13.6392660	0	65.0000000	65.0000000	16.0000000	34.0000000
Min	Min	450	20.8322222	21.1000000	9.6128675	2.2000000	37.8000000	35.6000000	12.8000000	29.1000000
PTS	PTS	450	9.7606667	7.8000000	6.9707460	0	34.7000000	34.7000000	4.4000000	13.7000000
FGM	FGM	450	3.6093333	2.9000000	2.5141474	0	11.5000000	11.5000000	1.6000000	5.0000000
FGA	FGA	450	7.6266667	6.3500000	5.1360380	0	23.6000000	23.6000000	3.5000000	10.7000000
FG_	FG%	450	46.5413333	46.0000000	9.2227581	0	74.7000000	74.7000000	42.5000000	50.5000000
_3PM	3PM	450	1.0857778	0.9000000	0.9162830	0	4.8000000	4.8000000	0.3000000	1.6000000
_3PA	3PA	450	3.0004444	2.6000000	2.3400169	0	11.8000000	11.8000000	1.1000000	4.6000000
3P	3P%	450	31.5088889	35.3000000	13.9244129	0	100.0000000	100.0000000	29.2000000	38.7000000
FTM	FTM	450	1.4604444	1.0000000	1.4712054	0	10.2000000	10.2000000	0.5000000	1.9000000
FTA	FTA	450	1.8675556	1.3000000	1.7835216	0	11.6000000	11.6000000	0.7000000	2.5000000
FT_	FT%	450	73.7275556	77.5500000	18.1902724	0	100.0000000	100.0000000	69.1000000	83.3000000
OREB	OREB	450	0.9533333	0.7000000	0.7847375	0	4.6000000	4.6000000	0.4000000	1.3000000
DREB	DREB	450	2.8482222	2.5000000	1.8778889	0	10.1000000	10.1000000	1.5000000	3.7000000
REB	REB	450	3.7931111	3.4000000	2.4960676	0	13.7000000	13.7000000	2.0000000	5.0000000
AST	AST	450	2.2813333	1.5000000	1.9624329	0	10.9000000	10.9000000	0.9000000	3.2000000
TOV	TOV	450	1.1217778	0.9000000	0.8230350	0	4.4000000	4.4000000	0.5000000	1.5000000
STL	STL	450	0.6524444	0.6000000	0.3815988	0	2.1000000	2.1000000	0.4000000	0.9000000
BLK	BLK	450	0.4477778	0.3000000	0.4350019	0	3.6000000	3.6000000	0.1000000	0.6000000
PF	PF	450	1.6455556	1.7000000	0.7512960	0	3.6000000	3.6000000	1.1000000	2.2000000
FP	FP	450	19.9100000	17.5000000	12.1579788	0.7000000	61.5000000	60.8000000	9.9000000	27.8000000
DD2	DD2	450	4.9422222	1.0000000	10.3683278	0	77.0000000	77.0000000	0	5.0000000
TD3	TD3	450	0.3044444	0	2.0793240	0	26.0000000	26.0000000	0	0
Plus_minus	Plus_minus	450	-0.1788889	-0.1500000	3.2924390	-11.0000000	8.6000000	19.6000000	-2.2000000	1.8000000

Introduction

Dans un échantillon de **450 joueurs**, nous avons analysé différentes variables démographiques, de performance, défensives et collectives, ainsi que leur impact sur le jeu. L'objectif est d'identifier les principales caractéristiques influençant les salaires des joueurs.

Commentaire des statistiques des variables

Variables Démographiques

Âge du joueur

- Moyenne : **26.06 ans**, Médiane : **25 ans**, Min : **19 ans**, Max : **39 ans**, Ecart-type : **4,3068**

L'âge moyen des joueurs est de 26,06 ans, indiquant un équilibre entre jeunes talents et joueurs expérimentés. La médiane proche de la moyenne montre une distribution relativement homogène

Les joueurs plus jeunes (19 ans) bénéficient d'un fort potentiel de développement, tandis que les plus âgés (jusqu'à 39 ans) apportent une expérience précieuse et un rôle de mentorat.

Variables de Performance

Matches joués (GP)

- Moyenne : **52.4 matchs**, Médiane : **58 matchs**, Min : **1**, Max : **84**, Écart-type : **23.3**

Le nombre de matchs joués reflète l'implication et la disponibilité d'un joueur au cours de la saison. Une moyenne de 52,4 matchs indique que certains joueurs sont régulièrement sur le terrain, tandis que d'autres jouent peu en raison de blessures, d'un faible temps de jeu ou d'un rôle secondaire.

Nombre de victoires (W)

- Moyenne : **26.74**, Médiane : **27**, Max : **64**, Écart-type : **15.77**

Le nombre de victoires est un indicateur de la performance collective. Un joueur dans une équipe à fort taux de victoires peut bénéficier d'une exposition médiatique plus forte, influençant son attractivité sur le marché et son salaire.

Nombre de défaites (L)

- Moyenne : **25.7**, Médiane : **25**, Max : **65**, Écart-type : **13.6**

Le nombre de défaites est directement lié aux victoires et met en avant la difficulté d'une saison pour certains joueurs. Un joueur performant dans une équipe en difficulté peut tout de même se démarquer par ses statistiques individuelles.

Ces statistiques reflètent **la répartition des performances collectives**. Les joueurs évoluant dans des équipes ayant un **nombre élevé de victoires** bénéficient généralement **d'une meilleure reconnaissance et d'un impact plus fort sur le marché des transferts**.

Minutes jouées par match (Min)

- Moyenne : **20.8 min**, Médiane : **21.1 min**, Min : **2.2**, Max : **37.8**, Écart-type : **9.6**

Le temps de jeu moyen par match indique l'importance d'un joueur dans la rotation de son équipe. Les joueurs ayant un temps de jeu élevé (proche du maximum de 37.8 min) sont souvent les joueurs majeurs de leur équipe. Toutefois, une charge excessive peut poser des problèmes de fatigue ou de risque accru de blessure.

Points par match (PTS)

- Moyenne : **9.76 PTS**, Médiane : **7.8 PTS**, Max : **34.7**, Écart-type : **6.97**

Le nombre de points par match est un indicateur clé de la contribution offensive. Un joueur marquant plus de 20 points par match est généralement une star offensive. Cependant, ce chiffre doit être mis en relation avec l'efficacité au tir (FG%) et le nombre de tirs tentés pour bien évaluer la performance offensive.

FGM (Tirs réussis) et FGA (Tirs tentés)

- Moyenne FGM : **3.6**, Médiane : **2.9**, Max : **11.5**, Écart-type : **2.51**
- Moyenne FGA : **7.6**, Médiane : **6.35**, Max : **23.6**, Écart-type : **5.14**

Le nombre de tirs réussis (FGM) est directement lié au nombre total de points marqués par un joueur. Un joueur avec un FGA élevé mais un faible FGM peut être inefficace s'il prend trop de tirs de mauvaise qualité.

FG% (Pourcentage de réussite aux tirs)

- Moyenne : **46.54%**, Médiane : **46%**, Max : **74.7%**, Écart-type : **9.22**

La moyenne de 46,54% indique que la plupart des joueurs ont une efficacité au tir modérée. Un joueur avec un pourcentage très bas peut être perçu comme peu efficace s'il ne convertit pas ses tentatives en points.

3PM et 3PA (Tirs à 3 points réussis et tentés)

- Moyenne 3PM : **1.09**, Médiane : **0.9**, Max : **4.8**, Écart-type : **0.92**
- Moyenne 3PA : **3.0**, Médiane : **2.6**, Max : **11.8**, Écart-type : **2.34**

Ces statistiques montrent que certains joueurs sont spécialisés dans les tirs à longue distance, tandis que d'autres privilégient les tirs à mi-distance ou proches du panier.

FTM et FTA (Lancers francs réussis et tentés)

- Moyenne FTM : **1.46**, Médiane : **1.0**, Max : **10.2**, Écart-type : **1.47**
- Moyenne FTA : **1.86**, Médiane : **1.3**, Max : **11.6**, Écart-type : **1.7**

Les lancers francs sont un indicateur clé du style de jeu d'un joueur. Un joueur obtenant beaucoup de lancers francs (FTA élevé) est souvent agressif dans ses attaques au panier, forçant l'adversaire à commettre des fautes.

FT% (Pourcentage de réussite aux lancers francs)

- Moyenne : **73.7%**, Médiane : **77.5%**, Max : **100%**, Écart-type : **18.19**

Un bon taux de réussite aux lancers francs est essentiel, surtout pour les joueurs qui obtiennent beaucoup d'opportunités sur la ligne.

Variables Défensives et Collectives

Rebonds offensifs et défensifs (OREB, DREB)

- Moyenne OREB : **0.95**, Médiane : **0.7**, Max : **4.6**, Écart-type : **0.78**
- Moyenne DREB : **2.85**, Médiane : **2.5**, Max : **10.1**, Écart-type : **1.88**

REB (Rebonds offensifs et défensifs)

- Moyenne : **3.79**, Médiane : **3.4**, Max : **13.7**, Écart-type : **2.5**

Les rebonds sont un élément clé du jeu défensif et offensif. Un bon rebondeur contribue à la récupération du ballon après un tir manqué, permettant à son équipe soit de relancer une attaque (OREB), soit de neutraliser l'offensive adverse (DREB).

- Les pivots et les intérieurs affichent souvent des valeurs élevées en rebonds, car leur positionnement près du panier leur permet de capter plus de ballons.
- Un joueur avec beaucoup de rebonds offensifs peut offrir des secondes chances à son équipe, tandis qu'un joueur dominant aux rebonds défensifs limite les opportunités adverses et favorise la transition offensive.

AST (Passes décisives)

- Moyenne : **2.28**, Médiane : **1.5**, Max : **10.9**, Écart-type : **1.96**

Les passes décisives sont un indicateur clé de la vision du jeu et du rôle d'un joueur dans la création offensive.

- Les joueurs avec une moyenne élevée de passes décisives (supérieure à 5) sont souvent des meneurs de jeu ou des créateurs qui organisent l'attaque et facilitent les opportunités pour leurs coéquipiers.
- Une faible moyenne en AST peut indiquer un profil plus individualiste ou un joueur jouant un rôle plus secondaire dans la distribution du jeu.

TOV (Balles perdues)

- Moyenne : **1.12**, Médiane : **0.9**, Max : **4.4**, Écart-type : **0.82**

Les pertes de balle sont un facteur négatif qui peut impacter la performance d'un joueur et de son équipe.

- Une moyenne trop élevée peut être un signe d'un joueur prenant beaucoup de risques offensifs mais manquant de précision dans ses passes ou son dribble.
- Cependant, les meneurs et les joueurs offensifs ayant beaucoup de responsabilités ont généralement un TOV plus élevé en raison de leur forte implication dans le jeu.

Un équilibre est donc nécessaire : trop de pertes de balle peuvent nuire au rendement global, mais un certain volume est inévitable pour les joueurs créateurs.

STL et BLK (Interceptions et Contres)

- Moyenne STL : **0.65**, Médiane : **0.6**, Max : **2.1**, Écart-type : **0.38**
- Moyenne BLK : **0.45**, Médiane : **0.3**, Max : **3.6**, Écart-type : **0.43**

Les interceptions et les contres sont des statistiques cruciales pour mesurer l'impact défensif d'un joueur

- Les interceptions (STL) sont généralement l'indicateur d'un jeu défensif actif, où le joueur anticipe les passes adverses et coupe les lignes de transmission.
- Les contres (BLK) mesurent la capacité à protéger le panier, une statistique dominée par les pivots et les ailiers forts.

Ces deux statistiques sont clés pour identifier des spécialistes défensifs capables de perturber les attaques adverses et de générer des opportunités en contre-attaque.

Variables d'Impact sur le Jeu

PF (Fautes personnelles)

- Moyenne : **1.64**, Médiane : **1.7**, Max : **3.6**, Écart-type : **0.75**

Les fautes personnelles sont un élément clé du jeu défensif et de la gestion du temps de jeu.

- Un nombre élevé de fautes peut forcer un joueur à réduire son agressivité défensive ou à être remplacé prématurément, limitant ainsi son impact sur le match.
- Les joueurs qui défendent avec intensité ont souvent un taux de fautes plus élevé, ce qui peut être un inconvénient s'ils ne parviennent pas à les gérer correctement.

Dans certains cas, une faible moyenne de fautes personnelles peut aussi signifier un manque d'engagement défensif, alors qu'un joueur avec beaucoup de fautes peut indiquer une défense physique mais risquée.

DD2 et TD3 (Double-Doubles et Triple-Doubles)

- Moyenne DD2 : **4.94**, Médiane : **1**, Max : **77**, Écart-type : **10.37**
- Moyenne TD3 : **0.3**, Médiane : **0**, Max : **26**, Écart-type : **2.07**

Ces statistiques sont des indicateurs de performances exceptionnelles, car elles mesurent la polyvalence et la capacité d'un joueur à exceller dans plusieurs domaines du jeu simultanément.

- Un double-double est souvent atteint par des joueurs ayant un fort impact offensif et défensif (ex. : points et rebonds pour les pivots, points et passes pour les meneurs).
- Un triple-double est une statistique rare, généralement obtenue par des joueurs d'élite capables d'affecter tous les aspects du jeu, notamment en points, passes et rebonds.

Les joueurs qui accumulent beaucoup de DD2 et TD3 sont souvent très recherchés et mieux rémunérés sur le marché.

+/- (Impact sur l'équipe)

- Moyenne : **-0.18**, Médiane : **-0.15**, Min : **-11**, Max : **8.6**, Écart-type : **3.29**

Le plus-minus (+/-) est une statistique qui mesure l'impact d'un joueur sur le score de son équipe lorsqu'il est sur le terrain.

- Un score positif signifie que l'équipe surperforme lorsque ce joueur joue.
- Un score négatif peut indiquer que l'équipe perd plus de points en sa présence, mais ce n'est pas toujours un facteur individuel (dépend aussi des coéquipiers et des adversaires).

Ce critère avancé est souvent utilisé pour évaluer l'efficacité globale d'un joueur et son influence sur le jeu collectif.

Salaire et Interprétation

Salaire du joueur

- Moyenne : 11 015 054 USD, Médiane : 5 250 000 USD, Max : 57 567 127 USD
- Écart-type très élevé : Indique une forte dispersion entre les joueurs stars et les autres.

Le salaire d'un joueur est influencé par de nombreux facteurs : performances statistiques, expérience, notoriété, et rôle dans l'équipe. Les joueurs vedettes perçoivent des salaires beaucoup plus élevés, créant un écart salarial significatif entre les différents profils.

Conclusion Générale

Ces statistiques offrent un aperçu clair des performances individuelles et collectives des joueurs. Les joueurs offensifs performants sont souvent les mieux rémunérés, tandis que les spécialistes défensifs ont un impact majeur sur les résultats collectifs.

Les meneurs de jeu et les joueurs polyvalents jouent un rôle clé dans la dynamique de l'équipe, et une bonne gestion des fautes personnelles est essentielle pour optimiser le temps de jeu.

Enfin, le salaire des joueurs varie fortement, favorisant principalement les stars et les joueurs les plus médiatisés. Les équipes les plus performantes offrent plus de visibilité et d'opportunités à leurs joueurs sur le marché des transferts.

b. Variable Qualitative

Team		
Team	Fréquence	Pourcentage
ATL	15	3.33
BKN	14	3.11
BOS	16	3.56
CHA	14	3.11
CHI	14	3.11
CLE	15	3.33
DAL	16	3.56
DEN	15	3.33
DET	15	3.33
GSW	16	3.56
HOU	12	2.67
IND	17	3.78
LAC	16	3.56
LAL	16	3.56
MEM	14	3.11
MIA	18	4.00
MIL	14	3.11
MIN	15	3.33
NOP	15	3.33
NYK	17	3.78
OKC	14	3.11
ORL	16	3.56
PHI	14	3.11
PHX	11	2.44
POR	17	3.78
SAC	15	3.33
SAS	15	3.33
TOR	15	3.33
UTA	13	2.89
WAS	16	3.56

Le tableau présente la fréquence et le pourcentage de membres des 30 équipes. La plupart des équipes comptent entre 14 et 17 membres, avec un pourcentage variant de 3,11 % à 3,78 %. Miami (MIA) a la fréquence la plus élevée (18 membres, 4,00 %), tandis que Phoenix (PHX) a la plus faible (11 membres, 2,44 %). Certaines équipes ont des fréquences similaires, ce qui indique une répartition relativement équilibrée.

Remarque : Cette variable est qualitative, alors que l'analyse repose sur des variables quantitatives pour la prédiction. Par conséquent, cette variable pourrait ne pas être utilisée dans le modèle prédictif.

Troisième partie : Modèles de régression linéaire simple

1. Choisir les variables pour le modèle

Nous avons utilisé la procédure PROC REG de SAS pour estimer le coefficient de détermination (R^2), la valeur de F et la probabilité critique de chaque variable afin d'identifier celles qui sont les plus pertinentes pour un modèle de régression linéaire simple.

```
PROC REG DATA=work.TAB_NBA_Final;  
  MODEL Salaire = Age--Plus_minus /* Variables quantitatives indépendantes de Age à Plus_minus */  
  / selection = rsquare;  
RUN;
```

Grâce à cette première analyse, nous avons sélectionné les variables ayant un R^2 supérieur à 0,4 afin de réduire leur nombre et optimiser l'identification de leur valeur F et de leur probabilité critique. Les variables retenues sont : PTS, FGM, FP, FGA, FTM, FTA, TOV, MIN, AST.

Ensuite, nous avons répété l'analyse pour chacune de ces variables individuellement :

```
PROC REG DATA=work.TAB_NBA_Final;  
  MODEL Salaire = PTS /* Régression sur PTS */  
  / CLB R INFLUENCE DWPROB;  
RUN;
```

À l'issue de ces analyses, nous avons établi un tableau récapitulatif présentant le coefficient de détermination (R^2), la valeur de F et la probabilité critique des différentes variables afin d'évaluer leur pertinence dans le modèle.

Variables in Model	R carre	F value	Pr > F
PTS	0,6673	898,6	< ,0001
FGM	0,6574	859,63	< ,0001
FP	0,6543	848,07	< ,0001
FGA	0,616	718,77	< ,0001
FTM	0,5749	605,99	< ,0001
FTA	0,5607	571,78	< ,0001
TOV	0,5302	505,68	< ,0001
MIN	0,5216	488,37	< ,0001
AST	0,4595	380,81	< ,0001

Sur la base du tableau récapitulatif, nous avons retenu **PTS** et **FGM** comme **variables quantitatives indépendantes**, car elles affichent un coefficient de détermination élevé et une probabilité critique inférieure à 0,5, indiquant ainsi une contribution significative au modèle de régression linéaire simple.

2. Régression linéaire simple

2.1 Le salaire en fonction de PTS (points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : salaire.

Variable quantitative indépendante : PTS (points).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final;
  MODEL Salaire = PTS / CLB R INFLUENCE DWPROB;
  /* Régression linéaire avec FGM comme variable quantitative indépendante */
  /* CLB : Intervalle de confiance des coefficients */
  /* R : Affichage des valeurs prévisionnelles, des résidus, leurs écarts-types, les résidus standardisés */
  /* INFLUENCE : Obtenir des résidus, des R-Student, des leviers */
  /* DWPROB : Test de Durbin-Watson pour l'autocorrélation des résidus */

  OUTPUT OUT=work.residus_PTS R=res_PTS;
  /* Création d'un dataset "residus_FGM" contenant les résidus */
RUN;

PROC UNIVARIATE DATA=work.residus_PTS;
  VAR res_PTS;
  /* Analyse des résidus pour tester la normalité */

  histogram / normal;
  /* Histogramme des résidus avec une courbe normale superposée */
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de la droite des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre le salaire et les points marqués (PTS). En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de la droite des moindres carrés.

Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	-3596392	598742	-6.01	<.0001
PTS	PTS	1	1496972	49938	29.98	<.0001

$$\widehat{\text{salaire}} = 1496972 \times \text{PTS} - 3596392$$

- Déterminer le coefficient de détermination.

R carré	0.6673
---------	--------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **66,73 %** par l'équation estimée de la droite entre deux variables **salaire** et **PTS**.

- La liaison globale entre ces deux variables est-elle significative ?

Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces deux variables.

Hypothèse : $H_0 : a = 0 \mid H_1 : a \neq 0$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	4.889138E16	4.889138E16	898.60	<.0001
Erreur	448	2.437485E16	5.440816E13		
Total sommes corrigées	449	7.326624E16			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H_0** . Cela signifie que la liaison entre le **salaire** et **PTS** est significative.

- Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.

Résultats estimés des paramètres							
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t	Intervalle de conf. à 95%
Intercept	Intercept	1	-3596392	598742	-6.01	<.0001	-4773083 -2419701
PTS	PTS	1	1496972	49938	29.98	<.0001	1398831 1595114

a appartient à [1398831 ; 1595114]

b appartient à [-4773083 ; -2419701]

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0 : E(\epsilon x) = 0 \mid H_1 : E(\epsilon x) \neq 0$

Test	Statistique	P-value
t de Student	t	0 Pr > t 1.0000

La probabilité critique est égale à 1, donc nous **acceptons H_0** . Cela signifie que les résidus ont une espérance nulle.

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.958097	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.089932	Pr > D	<0.0100

La probabilité critique est **inférieure à 0.05** nous amène à **rejeter H_0** , ce qui indique que les résidus **ne suivent pas** une loi normale.

Cela suggère que le modèle linéaire pourrait ne pas être parfaitement adapté aux données, et qu'il pourrait y avoir des biais, des erreurs de modélisation ou des caractéristiques non capturées, telles que des valeurs aberrantes ou une distribution asymétrique des résidus.

- Les résidus sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.


Hypothèse : H_0 : les résidus sont indépendants.

H_1 : les résidus sont dépendants.

Durbin-Watson D	2.017
------------------------	--------------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?



Nous avons observé **une forme d'entonnoir** dans le graphique des résidus. Cela indique une **hétéroscédasticité**, ce qui signifie que la variance des résidus varie en fonction des valeurs prédictives. Cela suggère que le modèle linéaire pourrait ne pas capturer correctement toutes les relations dans les données.

- Le modèle linéaire est-il approprié ?

Le modèle linéaire semble ne pas être totalement adapté en raison de l'hétéroscédasticité observée et de l'absence de normalité des résidus. Il est possible que des facteurs non modélisés, comme des valeurs aberrantes, influencent la performance du modèle.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times 2}{n} = \frac{2 \times 2}{450} = 0.0089$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0089. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0089**, comme présenté dans le tableau ci-dessous.

Observations (PTS)	hi	Observations (PTS)	hi
22	0,0098	229	0,0307
24	0,0125	255	0,0115
25	0,0142	260	0,0089
55	0,0099	261	0,0111
59	0,0097	272	0,016
93	0,0199	286	0,0093
105	0,0152	288	0,0137
109	0,0115	289	0,0114
112	0,0097	292	0,0105
119	0,0111	293	0,0139
120	0,016	298	0,0289
126	0,0152	347	0,0149
153	0,0217	362	0,0098
173	0,013	369	0,0098
187	0,0187	405	0,0149
206	0,0097	421	0,0139
214	0,0103	436	0,0142
217	0,0157	450	0,0101

Les observations 22, 24, 25, 55, 59, 93, 105, 109, 112, 119, 120, 126, 153, 173, 187, 206, 214, 217, 229, 255, 260, 261, 272, 286, 288, 289, 292, 293, 298, 347, 362, 369, 405, 421, 436 et 450 ont une forte influence sur le calcul de la pente de la droite et attirent la droite des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observations (PTS)	ri	Observations (PTS)	ri
15	-3,072	226	2,893
32	4,725	235	2,5
42	3,61	260	2,746
59	-3,548	261	2,362
93	1,818	347	2,116
124	2,048	352	2,475
130	2,013	362	-2,462
143	-2,569	369	2,585
144	2,772	385	3,594
145	-2,223	394	-2,185
164	2,975	405	2,71
191	-2,152	435	2,134
196	-2,75	439	-2,133
214	2,504	447	2,576

Les points 15, 32, 42, 59, 93, 124, 130, 143, 144, 145, 164, 191, 196, 214, 226, 235, 260, 261, 347, 352, 362, 369, 385, 394, 405, 435, 439, 447 sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

2.2 Le salaire en fonction de FGM (nombre moyen de tirs réussis par match)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : salaire.

Variable quantitative indépendante : FGM (nombre moyen de tirs réussis par match).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final;
  MODEL Salaire = FGM / CLB R INFLUENCE DWPROB;
  /* Régression linéaire avec FGM comme variable quantitative indépendante */
  /* CLB : Intervalle de confiance des coefficients */
  /* R : Affichage des valeurs prévisionnelles, des résidus, leurs écarts-types, les résidus standardisés */
  /* INFLUENCE : Obtenir des résidus, des R-Student, des leviers */
  /* DWPROB : Test de Durbin-Watson pour l'autocorrélation des résidus */

  OUTPUT OUT=work.residus_FGM R=res_FGM;
  /* Création d'un dataset "residus_FGM" contenant les résidus */
RUN;

PROC UNIVARIATE DATA=work.residus_FGM;
  VAR res_FGM;
  /* Analyse des résidus pour tester la normalité */

  histogram / normal;
  /* Histogramme des résidus avec une courbe normale superposée */
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de la droite des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre le salaire et le nombre moyen de tirs réussis par match (FGM). En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de la droite des moindres carrés.

Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	-3853844	617814	-6.24	<.0001
FGM	FGM	1	4119569	140506	29.32	<.0001

$$\widehat{\text{salaire}} = 4119569 \times \text{FGM} - 3853844$$

- Déterminer le coefficient de détermination.

R carré	0.6574
----------------	--------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **65,74%** par l'équation estimée de la droite entre deux variables **salaire** et **FGM**.

- La liaison globale entre ces deux variables est-elle significative ?

Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces deux variables.

Hypothèse : $H_0 : a = 0 \mid H_1 : a \neq 0$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	4.816499E 16	4.816499E16	859.63	<.0001
Erreur	448	2.510125E 16	5.602958E13		
Total sommes corrigées	449	7.326624E 16			

La probabilité critique est inférieure à 0.05 donc on **rejetons H_0** . La liaison entre le **salaire** et la **FGM** est significative.

- Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine. ?

Résultats estimés des paramètres								
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t	Intervalle de conf. à 95%	
Intercept	Intercept	1	-3853844	617814	-6.24	<.0001	-5068018	-2639671
FGM	FGM	1	4119569	140506	29.32	<.0001	3843437	4395702

a appartient à [3843437 ; 4395702]

b appartient à [-5068018 ; -2639671]

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0 : E(\epsilon x) = 0 \mid H_1 : E(\epsilon x) \neq 0$

Test	Statistique		P-value	
t de Student	t	0	Pr > t	1.0000

La probabilité critique est égale à 1, donc nous **acceptons H_0** . Cela signifie que les résidus ont une espérance nulle.

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests de normalité				
Test	Statistique		P-value	
Shapiro-Wilk	W	0.957079	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.093538	Pr > D	<0.0100

La probabilité critique est **inférieure à 0.05** nous amène à **rejeter H_0** , ce qui indique que les résidus **ne suivent pas** une loi normale.

Cela suggère que, tout comme le modèle précédent, ce modèle linéaire n'est pas parfaitement adapté aux données et qu'il pourrait y avoir des biais, des erreurs ou des caractéristiques non prises en compte, telles que des valeurs aberrantes ou une distribution asymétrique des résidus.

- Les résidus sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.


Hypothèse : H_0 : les résidus sont indépendants.

H_1 : les résidus sont dépendants.

Durbin-Watson D	1.990
-----------------	-------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?



Nous avons observé **une forme d'entonnoir** dans le graphique des résidus. Cela indique une **hétéroscédasticité**, ce qui signifie que la variance des résidus varie en fonction des valeurs prédictives. Cela suggère que le modèle linéaire pourrait ne pas capturer correctement toutes les relations dans les données.

- Le modèle linéaire est-il approprié ?

Le modèle linéaire semble ne pas être totalement adapté en raison de l'hétéroscédasticité observée et de l'absence de normalité des résidus. Il est possible que des facteurs non modélisés, comme des valeurs aberrantes, influencent la performance du modèle.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times 2}{n} = \frac{2 \times 2}{450} = 0.0089$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0089. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0089**, comme présenté dans le tableau ci-dessous.

Observations (FGM)	h_i	Observations (FGM)	h_i
15	0,0103	255	0,011
24	0,014	261	0,0125
25	0,0128	272	0,0166
55	0,0106	286	0,0114
59	0,009	288	0,0153
105	0,0153	289	0,01
109	0,0096	293	0,0149
112	0,011	298	0,0242
119	0,011	326	0,0093
120	0,014	347	0,0185
126	0,0128	362	0,009
153	0,0242	363	0,0106
173	0,0121	399	0,0194
187	0,018	405	0,0117
199	0,009	421	0,009
214	0,0125	436	0,0128
217	0,0138	450	0,0121
229	0,0242		

Les observations 22, 24, 25, 55, 59, 93, 105, 109, 112, 119, 120, 126, 153, 173, 187, 206, 214, 217, 229, 255, 260, 261, 272, 286, 288, 289, 292, 293, 298, 347, 362, 369, 405, 421, 436 et 450 ont une forte influence sur le calcul de la pente de la droite et attirent la droite des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observations (FGM)	r_i	Observations (FGM)	r_i
15	-3,401	226	3,411
32	4,313	235	2,482
42	3,325	260	2,862
55	-2,313	261	2,149
59	-3,363	352	2,332
93	2,971	362	-2,274
143	-2,576	369	2,753
144	3,053	385	3,459
164	2,82	394	-2,268
188	-2,02	405	3,14
191	-2,411	435	2,194
196	-2,986	439	-2,081
200	2,317	447	2,73
214	2,149		

Les points **32, 42, 59, 93, 124, 130, 143, 144, 145, 164, 191, 196, 214, 226, 235, 260, 261, 347, 352, 362, 369, 385, 394, 405, 435, 439, 447** sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

3. Conclusion

Dans l'analyse des deux modèles linéaires ci-dessus, nous avons constaté que les relations entre salaire et variables PTS et FGM sont significatives. Cependant, nous avons rencontré quelques problèmes en raison d'analyses précédentes, ce qui peut affecter la fiabilité des résultats. Voici une présentation détaillée de ces problèmes ainsi que des solutions possibles pour améliorer le modèle :

Problème d'hétéroscédasticité

- **Description** : Nous avons constaté que le graphique des résidus des deux modèles a une forme en entonnoir. Cela signifie que les points ne sont pas répartis uniformément de part et d'autre de l'axe des abscisses et que la variance des résidus n'est pas constante

Problème de non-normalité des résidus

- **Description** : À l'aide du test de Kolmogorov-Smirnov, nous avons constaté que la probabilité critique est inférieure à 0,05, ce qui signifie que les résidus ne suivent pas une loi normale. Étant donné que la normalité des résidus est une hypothèse importante pour la validité des tests statistiques, cette violation de la normalité dans les deux modèles pourrait affecter la précision des tests de significativité et des prédictions.
- **Solution proposée** :

- Le changement de variable $v = \ln(\text{salaire})$ ou $v = \sqrt{\text{salaire}}$ peut permettre de stabiliser la variance.

Problème de présence des observations atypiques

- **Description** : Avec un échantillon de **450 observations** dans les deux modèles, nous avons identifié environ **27 à 28 points mal reconstitués** et **35 à 36 points ayant une forte influence**. Ces observations peuvent peser exagérément dans le calcul des coefficients de régression et fausser les résultats. De plus, plusieurs de ces points sont présents dans les deux modèles (salaire en fonction de **PTS** et salaire en fonction de **FGM**), ce qui suggère une influence non négligeable sur la qualité des prédictions.
- **Solution proposée** :
 - Supprimer des points influents : Nous avons supprimé des **points mal reconstitués** plusieurs fois dans le modèle salaire en fonction de **FGM**, ce qui a **amélioré la probabilité critique** du test de **Kolmogorov-Smirnov** (elle est devenue supérieure à 0,05, donc meilleure). Cependant, il faut supprimer un grand nombre d'observations, ce qui réduit la taille de l'échantillon et donc la puissance statistique du modèle. Voici un tableau récapitulatif des **valeurs de R², valeur F, la probabilité critique** test de **Kolmogorov-Smirnov**,.. lorsque nous avons éliminé progressivement les points mal reconstitués dans le modèle de régression linéaire simple salaire en fonction de **FGM**.

Echantillon	r carre	valeur F	Pr > F	test Student	Durbin-Watson	Kolmogorov-Smirnov
450	0,6574	859,63	<.0001	0;1	1,99	<0,0100
427	0,7441	1230,1	<.0001	0;1	1,907	0,0238
397	0,7846	1438,54	<.0001	0;1	2,03	>0.15
377	0,8003	1502,58	<.0001	0;1	1,854	>0.15
362	0,8125	1559,62	<.0001	0;1	1,8	>0.15
351	0,8153	1540,92	<.0001	0;1	1,813	>0.15
344	0,8106	1463,28	<.0001	0;1	1,81	>0.15
341	0,8061	1409,43	<.0001	0;1	1,799	>0.15
337	0,796	1307,26	<.0001	0;1	1,795	>0.15

- Nous avons également les problèmes liés à l'élimination des points mal reconstitués
 - Réduire **la représentativité des données** et introduire un **biais**.
 - Si trop de points sont supprimés, le modèle peut **trop bien s'adapter aux données restantes**, réduisant sa **capacité de généralisation**.
 - Même après avoir supprimé les points mal reconstitués, le graphique des résidus a toujours **une forme d'entonnoir**, ce qui montre que la variance des erreurs reste instable.

Conclusion générale

À travers les analyses ci-dessus, les problèmes identifiés dans l'analyse des modèles de régression linéaire soulignent la nécessité d'améliorer le modèle en utilisant des modèles plus flexibles, plutôt que de simplement supprimer les observations atypiques. Ces ajustements permettront d'obtenir un modèle plus fiable et des résultats plus précis.

4. Changement du Salaire pour stabiliser la variance

D'après la conclusion précédente, éliminer les observations atypiques ne résoudra pas le problème. Nous avons donc décidé de modifier la variable salaire. Comme le graphique des résidus des modèles précédents a une forme en entonnoir, nous allons transformer salaire en racine carrée, racine cubique ou logarithme de salaire.

```
/* 1. Transformation de la variable d'pendante : racine carré du salaire */  
DATA work.TAB_NBA_Final;  
    SET work.TAB_NBA_Final;  
    Racine_Salaire = sqrt(Salaire);  
    Racine3_Salaire = Salaire**(1/3);  
    Ln_Salaire = log(Salaire);  
RUN;
```

Nous allons créer de nouvelles variables dans SAS comme dans le code ci-dessus. Ces variables correspondent aux transformations du salaire : racine carrée (Racine_Salaire), racine cubique (Racine3_Salaire) et logarithme (Ln_Salaire).

Nous utiliserons le coefficient de détermination pour choisir la meilleure transformation.

Variables	R-carré (Racine_Salaire)	R-carré (Racine3_Salaire)	R-carré (Ln_Salaire)
FP	0,6931	0,6826	0,5969
PTS	0,6826	0,6424	0,5596
FGM	0,6802	0,6628	0,5645

D'après le graphique, la racine carrée du salaire en fonction de la variable FP donne le coefficient de détermination le plus élevé. Nous avons donc retenu ce modèle avec la transformation Racine_salaire et FP. Nous avons également pris le modèle avec la transformation Racine3_Salaire et FP afin de comparer les deux.

4.1 Le $\sqrt{\text{salaire}}$ en fonction de FP (Fantasy Points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : $\sqrt{\text{salaire}}$.

Variable quantitative indépendante : FP (Fantasy Points).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
/* Régression avec la variable transformée : Racine_Salaire ~ PTS */
PROC REG DATA=work.TAB_NBA_Final;
  MODEL Racine_Salaire = FP / CLB R INFLUENCE DWPROB;
  OUTPUT OUT=residus_racine_salaire R=res;
RUN;
QUIT;

proc univariate data = residus_racine_salaire normal;
  var res; /* Analyse des résidus pour tester la normalité */
  histogram/normal; /* Histogramme des résidus avec une courbe normale superposée */
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de la droite des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre **la racine salaire** et les points de Fantasy (FP). En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de la droite des moindres carrés.

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	437.83254	87.79108	4.99	<.0001
FP	FP	1	119.74840	3.76437	31.81	<.0001

$$\sqrt{\text{salaire}} = 119.75840 \times \text{FP} + 437.83254$$

- Déterminer le coefficient de détermination.

R-Square	0.6931
-----------------	--------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **69, 31 %** par l'équation estimée de la droite entre deux variables $\sqrt{\text{salaire}}$ et **FP**.

- La liaison globale entre ces deux variables est-elle significative ?

Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces deux variables.

Hypothèse : $H_0 : a = 0 \mid H_1 : a \neq 0$

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	951718536	951718536	1011.94	<.0001
Error	448	421339299	940490		
Corrected Total	449	1373057835			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H_0** . Cela signifie que la liaison entre le $\sqrt{\text{salaire}}$ et **FP** est significative.

- Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.

Parameter Estimates								
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	95% Confidence Limits	
Intercept	Intercept	1	437.83254	87.79108	4.99	<.0001	265.29908	610.36601
FP	FP	1	119.74840	3.76437	31.81	<.0001	112.35038	127.14642

a appartient à [112.35038 ; 127.14642]

b appartient à [265.29908 ; 610.36601]

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0 : E(\varepsilon_x) = 0 \mid H_1 : E(\varepsilon_x) \neq 0$

Test	Statistique	P-value
t de Student	t	0 Pr > t 1.0000

La probabilité critique est égale à 1, donc nous **acceptons H_0** . Cela signifie que les résidus ont une espérance nulle.

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.996359	Pr < W	0.3981
Kolmogorov-Smirnov	D	0.033828	Pr > D	>0.1500

La probabilité critique est **supérieure à 0.05** donc nous amène à **accepter H_0** , ce qui indique que les résidus **suivent** une loi normale.

- Les résidus sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.



Hypothèse : H_0 : les résidus sont indépendants.

H_1 : les résidus sont dépendants.

Durbin-Watson D	1.902
-----------------	-------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?



Nous n'avons pas **de forme particulière** dans le graphique des résidus. Cela indique que les résidus ont une variance commune.

- Le modèle linéaire est-il approprié ?

Le modèle linéaire semble adapté, car nous n'avons plus de problème d'hétéroscédasticité ni d'absence de normalité des résidus. De plus, toutes les hypothèses sont satisfaites.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times 2}{n} = \frac{2 \times 2}{450} = 0.0089$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0089. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0089**, comme présenté dans le tableau ci-dessous.

Observation (FP)	h_i	Observation (FP)	h_i
15	0,0103	255	0,0092
24	0,0193	261	0,0097
25	0,0099	272	0,0122
30	0,0092	288	0,0101
93	0,009	289	0,0112
105	0,0119	293	0,0148
112	0,009	298	0,0283
120	0,0111	347	0,0244
124	0,0152	394	0,0111
126	0,0126	399	0,0182
153	0,0234	421	0,0121
173	0,0116	435	0,0114
187	0,011	436	0,0098
217	0,0126	439	0,0166
229	0,0278		

Les observations **15, 24, 25, 30, 93, 105, 112, 120, 124, 126, 153, 173, 187, 217, 229, 255, 261, 272, 288, 289, 293, 298, 347, 394, 399, 421, 435, 436 et 439** ont une forte influence sur le calcul de la pente de la droite et attirent la droite des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observation (FP)	ri	Observation (FP)	ri
15	-3,377	260	2,159
32	2,805	310	-2,185
42	2,799	323	2,048
59	-2,285	352	2,398
180	2,090	360	2,105
188	-2,360	396	2,048
191	-2,740	394	-2,642
196	-2,427	395	-2,373
211	-2,208	405	2,319
214	2,134	437	-2,286
226	2,104	439	-3,065
235	2,447	440	-2,002
238	-2,251	447	2,361

Les points **15, 32, 42, 59, 180, 188, 191, 196, 211, 214, 226, 235, 238, 269, 310, 323, 352, 360, 396, 394, 395, 405, 437, 439, 440 et 447** sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

4.2 Le $\sqrt[3]{\text{salaire}}$ en fonction de FP (Fantasy Points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : $\sqrt[3]{\text{salaire}}$.

Variable quantitative indépendante : FP (fantasy points).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final;  
  MODEL Racine3_Salaire = FP / CLB R INFLUENCE DWPROB;  
  OUTPUT OUT=residus_racine3_salaire R=res;  
RUN;  
QUIT;  
  
PROC UNIVARIATE DATA=residus_racine3_salaire NORMAL;  
  VAR res;  
  HISTOGRAM / NORMAL;  
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de la droite des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre **la racine salaire** et les fantasy points marqués (FP). En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de la droite des moindres carrés.

Parameter Estimates								
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	95% Confidence Limits	
Intercept	Intercept	1	81.64289	4.13602	19.74	<.0001	73.51449	89.77129
FP	FP	1	5.50779	0.17735	31.06	<.0001	5.15925	5.85632

$$\sqrt[3]{\text{salaire}} = 5.5.779 \times \text{FP} + 81.64289$$

- Déterminer le coefficient de détermination.

R-Square	0.6828
-----------------	---------------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **68,28 %** par l'équation estimée de la droite entre deux variables $\sqrt[3]{\text{salaire}}$ et **FP**.

- La liaison globale entre ces deux variables est-elle significative ?
Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces deux variables.

Hypothèse : $H_0: a = 0 \mid H_1: a \neq 0$

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	2013368	2013368	964.51	<.0001
Error	448	935182	2087.45874		
Corrected Total	449	2948550			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H_0** . Cela signifie que la liaison entre le $\sqrt[3]{\text{salaire}}$ et **FP** est significative.

- Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.

Parameter Estimates								
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	95% Confidence Limits	
Intercept	Intercept	1	81.64289	4.13602	19.74	<.0001	73.51449	89.77129
FP	FP	1	5.50779	0.17735	31.06	<.0001	5.15925	5.85632

a appartient à [5,15925 ; 5,85632]

b appartient à [73,51449 ; 89,77129]

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0: E(\epsilon x) = 0 \mid H_1: E(\epsilon x) \neq 0$

Test	Statistique		P-value	
t de Student	t	0	Pr > t	1.0000

La probabilité critique est égale à 1, donc nous **acceptons H_0** . Cela signifie que les résidus ont une espérance nulle.

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.995328	Pr < W	0.1963
Kolmogorov-Smirnov	D	0.023428	Pr > D	>0.1500

La probabilité critique est **supérieure à 0.05** donc nous amène à **accepter H_0** , ce qui indique que les résidus **suivent** une loi normale.

- Les résidus sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.



Hypothèse : H_0 : les résidus sont indépendants.

H_1 : les résidus sont dépendants.

Durbin-Watson D	1.901
------------------------	--------------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?



Nous n'avons pas **de forme particulière** dans le graphique des résidus. Cela indique que les résidus ont une variance commune.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times 2}{n} = \frac{2 \times 2}{450} = 0.0089$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0089. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0089**, comme présenté dans le tableau ci-dessous.

Observation (Racine3 -FP)	h_i	Observation (Racine3 -FP)	h_i
15	0,0103	255	0,0092
24	0,0193	261	0,0097
25	0,0099	272	0,0122
30	0,0092	288	0,0101
93	0,009	289	0,0112
105	0,0119	293	0,0148
112	0,009	298	0,0283
120	0,0111	347	0,0244
124	0,0152	394	0,0111
126	0,0126	399	0,0182
153	0,0234	421	0,0121
173	0,0116	435	0,0114
187	0,011	436	0,0098
217	0,0126	439	0,0166
229	0,0278		

Les observations **15, 24, 25, 30, 93, 105, 112, 120, 124, 126, 153, 173, 187, 217, 229, 255, 261, 272, 288, 289, 293, 298, 347, 394, 399, 421, 435, 436 et 439** ont une forte influence sur le calcul de la pente de la droite et attirent la droite des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observations (Racine3)	ri	Observations (Racine3)	ri
15	-3,141	211	-2,128
32	2,504	235	2,410
35	-2,285	238	-2,702
42	2,327	274	-2,122
59	-2,115	352	2,171
146	2,012	360	2,236
180	2,091	394	-2,393
188	-2,171	395	-2,320
191	-2,542	431	-2,603
196	-2,230	437	-2,165
210	-2,498	439	-2,819

Les points **15, 32, 35, 42, 59, 146, 180, 188, 191, 196, 210, 211, 235, 238, 274, 352, 360, 394, 395, 431, 437 et 439** sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

4.3 Conclusion

Les modèles semblent adaptés, car nous n'avons plus de problème d'hétéroscédasticité ni d'absence de normalité des résidus. De plus, toutes les hypothèses sont satisfaites.

Parmi les modèles testés, celui basé sur la transformation $\sqrt{\text{Salaire}} \sim \text{FP}$ a été retenu. Il permet de mieux respecter les hypothèses de la régression linéaire, notamment la **normalité** et l'**indépendance des résidus**, tout en conservant un bon pouvoir explicatif ($R^2 = 69,31 \%$).

Quatrième partie : Modèles de régression linéaire avec deux variables

1. Choisir les variables pour le modèle

Nous avons utilisé la procédure PROC REG de SAS pour estimer le coefficient de détermination (R^2), la valeur de F et la probabilité critique de chaque variable afin d'identifier celles qui sont les plus pertinentes pour un modèle de régression linéaire simple.

```
PROC REG DATA=work.TAB_NBA_Final;  
  MODEL Salaire = Age--Plus_minus /* Variables quantitatives indépendantes de Age à Plus_minus */  
  / selection = rsquare;  
RUN;
```

Grâce à cette première analyse, nous avons sélectionné les variables ayant un R^2 supérieur à 0,6780 afin de réduire leur nombre et optimiser l'identification de leur valeur F et de leur probabilité critique. Les variables retenues sont : Age-PTS, Age-FGM, PTS-Plus_minus, L-PTS, PTS-FGA, FGM-Plus_minus, PTS-DD2, Age-FP, L-FGM.

Ensuite, nous avons répété l'analyse pour chacune de ces variables individuellement :

```
PROC REG DATA=work.TAB_NBA_Final;  
  MODEL Salaire = AGE PTS /* Régression sur PTS */  
  / R;  
RUN;
```

À l'issue de ces analyses, nous avons établi un tableau récapitulatif présentant le coefficient de détermination (R^2), la valeur de F et la probabilité critique des différentes variables afin d'évaluer leur pertinence dans le modèle.

Variables	R-carré	F Value	Pr > T
Age PTS	0,6987	518.38	<.0001
Age FGM	0,6987	500.99	<.0001
PTS Plus_minus	0,6987	497.92	<.0001
L PTS	0,6987	488.57	<.0001
PTS FGA	0,6987	483.89	<.0001
FGM Plus_minu	0,6987	479.46	<.0001
PTS DD2	0,6987	474.45	<.0001
Age FP	0,6987	471.48	<.0001
L FGM	0,6987	470.82	<.0001

Sur la base du tableau récapitulatif, nous avons retenu **AGE-PTS** comme **variables quantitatives indépendantes**, car elles affichent un coefficient de détermination élevé et une probabilité critique inférieure à 0,5, indiquant ainsi une contribution significative au modèle de régression linéaire deux variables.

2. Régression linéaire deux variables

2.1 Le salaire en fonction de Age et PTS (points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : salaire.

Variable quantitative indépendante : Age et PTS (points).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final Corr;  
  MODEL Salaire = AGE PTS / CLB R INFLUENCE DWPROB VIF ;  
  /* Régression linéaire avec AGE et PTS comme variable quantitative indépendante */  
  /* CLB : Intervalle de confiance des coefficients */  
  /* R : Affichage des valeurs prévisionnelles, des résidus, leurs écarts-types, les résidus standardisés */  
  /* INFLUENCE : Obtenir des résidus, des R-Student, des leviers */  
  /* DWPROB : Test de Durbin-Watson pour l'autocorrélation des résidus */  
  /* Corr : Affiche la matrice de corrélation entre toutes les variables numériques du dataset */  
  /* VIF : Calcule la Variance Inflation Factors pour détecter la multicolinéarité entre variables  
explicatives */  
  
  OUTPUT OUT=work.residus_AP R=res_AP;  
  /* Création d'un dataset "residus_AP" contenant les résidus */  
RUN;  
  
PROC UNIVARIATE DATA=work.residus_AP;  
  VAR res_AP;  
  /* Analyse des résidus pour tester la normalité */  
  
  histogram / normal;  
  /* Histogramme des résidus avec une courbe normale superposée */  
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de l'hyperplan des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre le salaire, l'âge et les points marqués (PTS) et évaluer la relation entre les variables. En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

- Déterminer l'équation estimée de l'hyperplan des moindres carrés.

Parameter Estimates				
Variable	Label	DF	Parameter Estimate	Standard Error
Intercept	Intercept	1	-16956742	2037938
Age	Age	1	533474	78122
PTS	PTS	1	1441323	48267

$$\text{Salaire} = -16956742 + \text{âge} \times (533474) + \text{PTS} \times (1441323)$$

- Déterminer le coefficient de détermination.

R-Square	0.6987
-----------------	---------------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **69,87%** par l'équation estimée de l'hyperplan entre **Age, PTS et Salaire**.

- La liaison globale entre toutes ces variables est-elle significative ?
Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces variables.

$$H_0: CM_{\text{exp}} = CM_{\text{res}}$$

$$H_1: CM_{\text{exp}} \neq CM_{\text{res}}$$

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	2	5.1194E16	2.5597E16	518.38	<.0001
Error	447	2.207224E16	4.937861E13		
Corrected Total	449	7.326624E16			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H_0** . Cela signifie que la liaison entre le **Age, PTS et Salaire** est significative.

- Quelles sont les variables qui ont une influence significative sur le salaire ?
Tests marginaux de Student :

$$H_0: \text{Pour tout } j \text{ allant de } 1 \text{ à } 2, \beta_j = 0.$$

$$H_1: \text{Pour tout } j \text{ allant de } 1 \text{ à } 2 / \beta_j \neq 0.$$

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	-16956742	2037938	-8.32	<.0001
Age	Age	1	533474	78122	6.83	<.0001
PTS	PTS	1	1441323	48267	29.86	<.0001

Age et PTS ont une influence significative sur le salaire.

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0: E(\epsilon x) = 0$

$H_1: E(\epsilon x) \neq 0$

t de Student	t	0	Pr > t	1.0000
--------------	---	---	---------	--------

La probabilité critique est égale à 1 donc on accepte H_0 .

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.971236	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.070534	Pr > D	<0.0100

La probabilité critique est **inférieure à 0.05** nous amène à **rejeter H_0** , ce qui indique que les résidus **ne suivent pas** une loi normale.

Cela suggère que le modèle linéaire pourrait ne pas être parfaitement adapté aux données, et qu'il pourrait y avoir des biais, des erreurs de modélisation ou des caractéristiques non capturées, telles que des valeurs aberrantes ou une distribution asymétrique des résidus.

- Sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.

Hypothèse : H_0 : les résidus sont indépendants.


H_1 : les résidus sont dépendants.

Durbin-Watson D	1.966
------------------------	--------------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?

Graphique des résidus



Nous avons observé **une forme d'entonnoir** dans le graphique des résidus. Cela indique une **hétéroscédasticité**, ce qui signifie que la variance des résidus varie en fonction des valeurs prédictives. Cela suggère que le modèle linéaire pourrait ne pas capturer correctement toutes les relations dans les données.

- Le modèle linéaire est-il approprié ?

Le modèle linéaire semble ne pas être totalement adapté en raison de l'hétéroscédasticité observée et de l'absence de normalité des résidus. Il est possible que des facteurs non modélisés, comme des valeurs aberrantes, influencent la performance du modèle.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times (k+1)}{n} = \frac{2 \times 3}{450} = 0.0133$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0133. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0133**, comme présenté dans le tableau ci-dessous.

Observation (AGE-PTS)	hi	Observation (AGE-PTS)	hi
10	0,0203	229	0,0310
24	0,0139	261	0,0148
25	0,0182	272	0,0223
49	0,0141	287	0,0205
55	0,0135	288	0,0160
59	0,0133	289	0,0152
70	0,0231	293	0,0296
93	0,0155	298	0,0305
105	0,0156	312	0,0140
108	0,0151	325	0,0141
109	0,0167	345	0,0141
120	0,0161	347	0,0151
126	0,0153	360	0,0287
147	0,0238	362	0,0148
153	0,0218	367	0,0150
173	0,0147	369	0,0152
174	0,0175	399	0,0224
187	0,0188	405	0,0232
201	0,0232	408	0,0287
217	0,0161	421	0,0148
219	0,0184	436	0,0169
226	0,0135	439	0,0150
228	0,0172		

Les observations 10, 24, 25, 49, 55, 59, 70, 93, 105, 108, 109, 120, 126, 147, 153, 173, 174, 187, 201, 217, 219, 226, 228, 229, 261, 272, 287, 288, 289, 293, 298, 312, 325, 345, 347, 360, 362, 367, 369, 399, 405, 408, 421, 436 et 439 ont une forte influence sur le calcul de la pente de la droite et attirent de l'hyperplan des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observation (AGE-PTS)	ri	Observation (AGE-PTS)	ri
15	-2,755	235	2,606
32	4,860	260	2,831
42	3,484	261	2,064
59	-3,319	323	2,122
99	2,132	346	2,019
124	2,079	347	2,130
140	-2,042	352	2,642
143	-2,312	362	-2,102
144	2,672	369	2,216
164	3,112	385	3,361
196	-2,582	405	2,226
211	-2,026	435	2,481
214	2,662	447	2,558
226	2,527		

Les points 15, 32, 42, 59, 99, 124, 140, 143, 144, 145, 164, 196, 211, 214, 226, 235, 260, 261, 323, 346, 357, 352, 362, 369, 385, 405, 435 et 447 sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

Détection de la multicolinéarité

- Est-ce qu'il y a des variables qui sont corrélées 2 par 2 ?

Correlation				
Variable	Label	Age	PTS	Salaire
Age	Age	1.0000	0.1688	0.3127
PTS	PTS	0.1688	1.0000	0.8169
Salaire		0.3127	0.8169	1.0000

Seuil = 0,8 en valeur absolue

Les AGE et PTS ne sont pas corrélés.

- Déterminer un ou plusieurs groupes de variables corrélées entre elles ?

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	-16956742	2037938	-8.32	<.0001	0
Age	Age	1	533474	78122	6.83	<.0001	1.02934
PTS	PTS	1	1441323	48267	29.86	<.0001	1.02934

Les variables Age et PTS ont des vifs proches de 1 donc il n'y a pas de multicolinéarité entre ces 2 var.

2.2 Conclusion

Bien qu'il n'y ait pas de problème de multicolinéarité, le modèle linéaire ne semble pas totalement adapté en raison de l'hétéroscédasticité observée et de l'absence de normalité des résidus. Il est possible que des facteurs non modélisés, comme des valeurs aberrantes, influencent la performance du modèle.

3. Changement du Salaire pour stabiliser la variance

Nous avons comparé le coefficient de détermination (R^2) des modèles à deux variables en testant différentes transformations de la variable dépendante (salaire), notamment la racine carrée ($\sqrt{\text{Salaire}}$) et la racine cubique ($\sqrt[3]{\text{Salaire}}$). Les combinaisons testées sont :

Variables	R-carré (Racine_Salaire)	R-carré (Racine3_Salaire)
Age FP	0,7217	0,7126
Age FGM	0,7205	0,7048
Age PTS	0,7202	0,7019
W FP	0,7062	0,7056
FP Plus_minus	0,7042	0,6929

D'après le tableau, le modèle Age - FP avec la racine carrée du salaire obtient le meilleur R^2 (0,7217). Cela signifie qu'il explique mieux la variation du salaire que les autres modèles testés.

Conclusion

Parmi les modèles, le modèle avec les Age et FP, en utilisant la racine carrée du salaire ($\sqrt{\text{Salaire}}$) comme variable dépendante, est le plus pertinent. C'est pourquoi nous avons choisi cette transformation pour la suite de l'analyse.

3.1 Le $\sqrt{\text{salaire}}$ en fonction de Age et FP (Fantasy Points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : $\sqrt{\text{salaires}}$.

Variable quantitative indépendante : Age et FP (Fantasy Points).

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final Corr;
  MODEL Racine_Salaire = AGE FP / CLB R INFLUENCE DWPROB VIF;
  /* Régression linéaire avec AGE et FP comme variable quantitative indépendante */
  /* CLB : Intervalle de confiance des coefficients */
  /* R : Affichage des valeurs prévisionnelles, des résidus, leurs écarts-types, les résidus standardisés */
  /* INFLUENCE : Obtenir des résidus, des R-Student, des leviers */
  /* DWPROB : Test de Durbin-Watson pour l'autocorrélation des résidus */
  /* Corr : Affiche la matrice de corrélation entre toutes les variables numériques du dataset */
  /* VIF : Calcule la Variance Inflation Factors pour détecter la multicollinéarité entre variables
explicatives */

  OUTPUT OUT=work.residus_AFP R=res_AFP;
  /* Création d'un dataset "residus_AP" contenant les résidus */
RUN;

PROC UNIVARIATE DATA=work.residus_AFP;
  VAR res_AFP;
  /* Analyse des résidus pour tester la normalité */

  histogram / normal;
  /* Histogramme des résidus avec une courbe normale superposée */
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de l'hyperplan des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre le $\sqrt{\text{salaires}}$, l'âge et les points de Fantasy (FP) et évaluer la relation entre les variables. En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de l'hyperplan des moindres carrés.

Paramete				
Variable	Label	DF	Parameter Estimate	Standard Error
Intercept	Intercept	1	-1287.50043	268.34591
Age	Age	1	69.95934	10.33806
FP	FP	1	114.82811	3.66211

$$\sqrt{\text{salaire}} = -1287,50043 + \text{âge} \times (69,95934) + \text{FP} \times (114,82811)$$

- Déterminer le coefficient de détermination.

R-Square	0.7217	Proche de 1
-----------------	---------------	-------------

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **72,17%** par l'équation estimée de l'hyperplan entre **Age, FP et $\sqrt{\text{salaire}}$** .

- La liaison globale entre toutes ces variables est-elle significative ?
Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces variables.

$$H_0: CM_{\text{exp}} = CM_{\text{res}}$$

$$H_1: CM_{\text{exp}} \neq CM_{\text{res}}$$

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	2	990872850	495436425	579.46	<.0001
Error	447	382184985	855000		
Corrected Total	449	1373057835			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H_0** . Cela signifie que la liaison entre le **Age, FP et $\sqrt{\text{salaire}}$** est significative.

- Quelles sont les variables qui ont une influence significative sur le salaire ?
Tests marginaux de Student :

$$H_0: \text{Pour tout } j \text{ allant de } 1 \text{ à } 2, \beta^j = 0.$$

$$H_1: \text{Pour tout } j \text{ allant de } 1 \text{ à } 2 / \beta^j \neq 0.$$

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	-1287.50043	268.34591	-4.80	<.0001
Age	Age	1	69.95934	10.33806	6.77	<.0001
FP	FP	1	114.82811	3.66211	31.36	<.0001

Âge et FP ont une influence significative sur le $\sqrt{\text{salaire}}$

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : $H_0 : E(\varepsilon_x) = 0$

$H_1 : E(\varepsilon_x) \neq 0$

t de Student	t	0	Pr > t	1.0000
--------------	---	---	---------	--------

La probabilité critique est égale à 1 donc on accepte H_0 .

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.998234	Pr < W	0.9297
Kolmogorov-Smirnov	D	0.026382	Pr > D	>0.1500

La probabilité critique est **supérieure à 0.05** donc nous amène à **accepter H_0** , ce qui indique que les résidus **suivent** une loi normale.

- Sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.


Hypothèse : H_0 : les résidus sont indépendants.

H_1 : les résidus sont dépendants.

Durbin-Watson D	1.905
-----------------	-------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?
Graphique des résidus



Nous n'observons pas de forme particulière dans le graphique des résidus, ce qui indique que leur variance est constante.

- Le modèle linéaire est-il approprié ?

Le modèle semble adapté, car nous n'avons plus de problème d'hétéroscédasticité ni d'absence de normalité des résidus. De plus, toutes les hypothèses sont satisfaites.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times (k+1)}{n} = \frac{2 \times 3}{450} = 0.0133$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0133. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0133**, comme présenté dans le tableau ci-dessous.

Observation (AGE-FP)	hi	Observation (AGE-FP)	hi
10	0,0194	261	0,0133
15	0,0158	272	0,0186
24	0,0201	287	0,0198
25	0,0139	289	0,0154
49	0,0143	293	0,0297
70	0,0223	298	0,0303
108	0,0146	312	0,0152
109	0,0139	325	0,0141
124	0,0152	347	0,0244
147	0,0248	360	0,0283
153	0,0234	362	0,0138
173	0,0135	367	0,0161
174	0,0182	394	0,0153
201	0,0241	399	0,0196
219	0,0198	405	0,0174
228	0,0167	408	0,0293
229	0,0279	439	0,0251

Les observations **10, 15, 24, 25, 49, 70, 108, 109, 124, 147, 153, 173, 174, 201, 219, 228, 229, 261, 272, 287, 289, 293, 298, 312, 325, 347, 360, 362, 367, 394, 399, 405, 408 et 439** ont une forte influence sur le calcul de la pente de la droite et attirent de l'hyperplan des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observation (AGE-FP)	r_i	Observation (AGE-FP)	r_i
15	-3,042	235	2,563
32	2,907	238	-2,288
35	-2,331	260	2,211
42	2,633	287	-2,134
59	-2,030	323	2,205
99	2,138	352	2,560
180	2,423	394	-2,337
191	-2,483	395	-2,218
196	-2,240	437	-2,495
211	-2,577	439	-2,598
214	2,262	447	2,323

Les points **15, 32, 35, 42, 59, 99, 180, 191, 196, 211, 214, 235, 238, 260, 287, 323, 352, 394, 395, 437, 439 et 447** sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

Détection de la multicolinéarité

- Est-ce qu'il y a des variables qui sont corrélées 2 par 2 ?

Correlation				
Variable	Label	Age	FP	Racine_Salaire
Age	Age	1.0000	0.1985	0.3308
FP	FP	0.1985	1.0000	0.8325
Racine_Salaire		0.3308	0.8325	1.0000

Seuil = 0,8 en valeur absolue

Les AGE et FP ne sont pas corrélés.

- Déterminer un ou plusieurs groupes de variables corrélées entre elles ?

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	-1287.50043	268.34591	-4.80	<.0001	0
Age	Age	1	69.95934	10.33806	6.77	<.0001	1.04104
FP	FP	1	114.82811	3.66211	31.36	<.0001	1.04104

Les variables Âge et FP ont des vifs proches de 1 donc il n'y a pas de multicolinéarité entre ces 2 var.

3.2 Conclusion

Dans notre analyse ci-dessus, nous avons observé que la relation entre $\sqrt{\text{salaire}}$ et les variables Âge et FP est significative. Même si nous avons corrigé les problèmes d'hétéroscédasticité et de non-normalité des résidus, la présence d'observations atypiques reste un souci.

Cela peut donc affecter la fiabilité des résultats.

Cinquième partie : Modèles de régression linéaire avec plusieurs variables

1. Choisir les variables pour le modèle

D'après l'analyse précédente sur le modèle à deux variables, nous avons constaté que l'utilisation de la racine carrée du salaire ($\sqrt{\text{salaire}}$) donnait les résultats les plus pertinents. Nous avons donc choisi d'appliquer cette transformation pour le modèle multivariable.

Comme précédemment, nous avons comparé le coefficient de détermination (R^2) des modèles à plusieurs variables, en utilisant $\sqrt{\text{salaire}}$ comme variable dépendante.

Pour identifier le modèle multivariable le plus adapté, nous avons testé différentes sélections de variables avec PROC REG, en utilisant deux méthodes :

- Stepwise
- Forward

```
/* Exécution de la procédure PROC REG sur le dataset work.TAB_NBA_Final */  
PROC REG DATA=work.TAB_NBA_Final CORR;  
/* Modèle de régression avec Racine_Salaire comme variable dépendante */  
/* age--Plus_minus représente l'ensemble des variables explicatives */  
MODEL Racine_Salaire = age--Plus_minus  
/* Utilisation de la sélection de variables STEPWISE */  
/* slentry=0.05 : Une variable entre dans le modèle si sa p-valeur < 0.05 */  
/* slstay=0.05 : Une variable reste dans le modèle si sa p-valeur < 0.05 */  
/ SELECTION=STEPWISE SLENTRY=0.05 SLSTAY=0.05;  
RUN;
```

Les combinaisons testées sont :

Variables	Méthode	R-carré
Age, W, PTS, FT_percent, FP	Stepwise	0,7444
Age, W, PTS, FT_percent, FP	Forward	0,7444

D'après les résultats obtenus, nous constatons que les méthodes Stepwise et Forward, avec les variables Age, W, PTS, FT_percent et FP, aboutissent au même modèle. De plus, ce modèle présente le R^2 (0,7444) le plus élevé, ce qui signifie qu'il explique le mieux la variabilité de la variable dépendante. Nous avons donc choisi de le retenir pour la suite de l'analyse.

Correlation							
Variable	Label	Age	W	PTS	FT_percent	FP	Racine_Salaire
Age	Age	1.0000	0.2911	0.1688	0.1729	0.1985	0.3308
W	W	0.2911	1.0000	0.4199	0.2640	0.4498	0.4767
PTS	PTS	0.1688	0.4199	1.0000	0.3530	0.9550	0.8262
FT_percent	FT_percent	0.1729	0.2640	0.3530	1.0000	0.3152	0.2652
FP	FP	0.1985	0.4498	0.9550	0.3152	1.0000	0.8325
Racine_Salaire		0.3308	0.4767	0.8262	0.2652	0.8325	1.0000

D'après le tableau ci-dessus, nous pouvons constater que ce modèle présente un problème de multicollinéarité entre les variables PTS et FP ($r = 0,9550$), ce qui introduit de la redondance dans le modèle.

Afin de résoudre ce problème, nous avons décidé d'éliminer l'une de ces deux variables, en nous basant sur les analyses suivantes.

Nous allons évaluer le coefficient de détermination (R^2), la valeur F et les tests marginaux de student en comparant deux modèles distincts :

- Modèle 1 : Age, W, PTS, FT_percent
- Modèle 2 : Age, W, FT_percent, FP

Variables	R-carré (Racine_Salaire)	F Value	Pr > T
Age, W, PTS, FT_percent	0,734	306.92	<.0001
Age, W, FT_percent, FP	0,7284	298.36	<.0001

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	-811.71650	295.39927	-2.75	0.0062
Age	Age	1	72.20728	10.43769	6.92	<.0001
W	W	1	13.28407	3.10181	4.28	<.0001
PTS	PTS	1	193.22435	7.03548	27.46	<.0001
FT_percent	FT_percent	1	-6.63817	2.54705	-2.61	0.0095

Parameter Estimates						
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	Intercept	1	-1103.84318	297.99537	-3.70	0.0002
Age	Age	1	63.35357	10.55986	6.00	<.0001
W	W	1	10.32541	3.17612	3.25	0.0012
FT_percent	FT_percent	1	-2.75061	2.53898	-1.08	0.2792
FP	FP	1	110.56655	4.09296	27.01	<.0001

D'après les tableaux d'analyse ci-dessus, nous pouvons constater que le modèle 1 présente un R^2 et une valeur F plus élevés que le modèle 2. De plus, dans le modèle 2, la variable FT_percent n'a pas d'influence sur le modèle, alors que dans le modèle 1, cette variable a une influence significative.

Nous avons donc décidé de retenir le modèle 1 (Âge, W, PTS, FT_percent) pour le modèle multivariable.

2. Régression linéaire plusieurs variables

2.1 Le $\sqrt{\text{salaire}}$ en fonction de Age W (wins) FT_PERCENT((Free Throw Percentage) et PTS (points)

Population : des joueurs NBA (n=450).

Variable quantitative dépendante : $\sqrt{\text{salaire}}$

Variable quantitative indépendante : l'âge, le nombre de victoires, le pourcentage de réussite aux lancers francs, et le nombre de points marqués. (AGE W FR_PERCENT PTS)

Nous avons utilisé deux procédures SAS pour analyser un modèle linéaire. La première **PROC REG** permet d'effectuer une régression linéaire et d'examiner les résidus, les influences des points et l'autocorrélation. La seconde, **PROC UNIVARIATE**, est utilisée pour tester la normalité des résidus à l'aide d'un histogramme comparé à une distribution normale. Ces analyses permettent de valider les hypothèses du modèle linéaire.

```
PROC REG DATA=work.TAB_NBA_Final Corr;  
  MODEL Salaire = AGE W FR_PERCENT PTS / CLB R INFLUENCE DWPROB VIF ;  
  /* Régression linéaire avec AGE AGE W FR_PERCENT et PTS comme variable quantitative  
  indépendante */  
  /* CLB : Intervalle de confiance des coefficients */  
  /* R : Affichage des valeurs prévisionnelles, des résidus, leurs écarts-types, les résidus standardisés */  
  /* INFLUENCE : Obtenir des résidus, des R-Student, des leviers */  
  /* DWPROB : Test de Durbin-Watson pour l'autocorrélation des résidus */  
  /* Corr : Affiche la matrice de corrélation entre toutes les variables numériques du dataset */  
  /* VIF : Calcule la Variance Inflation Factors pour détecter la multicollinéarité entre variables  
  explicatives */  
  
  OUTPUT OUT=work.residus_step R=res_step;  
  /* Création d'un dataset "residus_step" contenant les résidus */  
RUN;  
  
PROC UNIVARIATE DATA=work.residus_step;  
  VAR res_step;  
  /* Analyse des résidus pour tester la normalité */  
  
  histogram / normal;  
  /* Histogramme des résidus avec une courbe normale superposée */  
RUN;
```

Après avoir réalisé les analyses préliminaires à l'aide des procédures **PROC REG** et **PROC UNIVARIATE**, nous avons approfondi notre étude en examinant les aspects inférentiels et descriptifs du modèle linéaire. L'objectif principal était de déterminer l'équation estimée de la droite des moindres carrés, de calculer le coefficient de détermination, et d'évaluer la significativité de la relation entre le $\sqrt{\text{salaires}}$, l'âge, le nombre de victoires(W), le pourcentage de réussite aux lancers francs (FT_PERCENT) et les points marqués (PTS) et évaluer la relation entre les variables. En parallèle, nous avons testé diverses hypothèses concernant les résidus du modèle, telles que leur normalité, leur indépendance, et leur variance homogène, afin de valider la pertinence du modèle linéaire pour cette analyse.

Aspects inférentiels et descriptifs

- Déterminer l'équation estimée de l'hyperplan des moindres carrés.

Parameter				
Variable	Label	DF	Parameter Estimate	Standard Error
Intercept	Intercept	1	-811.71650	295.39927
Age	Age	1	72.20728	10.43769
W	W	1	13.28407	3.10181
FT_percent	FT_percent	1	-6.63817	2.54705
PTS	PTS	1	193.22435	7.03548

$$\sqrt{\text{salairé}} = -811.71650 + \text{âge} \times (72.20728) + W \times (13.28407) - \text{FT_PERCENT} \times (6.63817) + \text{PTS} \times (193.22435)$$

- Déterminer le coefficient de détermination.

R-Square	0.7340
-----------------	---------------

Proche de 1

L'équation estimée de la droite s'ajuste bien aux données.

La variation du salaire est expliquée à **73,40%** par l'équation estimée de l'hyperplan entre **Age, W, FT_PERCENT, PTS** et $\sqrt{\text{salairé}}$.

- La liaison globale entre toutes ces variables est-elle significative ?
Nous avons utilisé le **test de Fisher** pour vérifier la liaison entre ces variables.

$$H_0: CM_{\text{exp}} = CM_{\text{res}}$$

$$H_1: CM_{\text{exp}} \neq CM_{\text{res}}$$

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	4	1007765515	251941379	306.92	<.0001
Error	445	365292320	820882		
Corrected Total	449	1373057835			

La probabilité critique est inférieure à 0.05 donc nous **rejetons H₀**. Cela signifie que la liaison entre le **Age, W, FT_PERCENT, PTS** et $\sqrt{\text{salairé}}$ est significative.

- Quelles sont les variables qui ont une influence significative sur le salaire ?

Tests marginaux de Student :

H_0 : Pour tout j allant de 1 à 4, $\beta_j = 0$.

H_1 : Pour tout j allant de 1 à 4 / $\beta_j \neq 0$.

Correlation						
Variable	Label	Age	W	FT_percent	PTS	Racine_Salaire
Age	Age	1.0000	0.2911	0.1729	0.1688	0.3308
W	W	0.2911	1.0000	0.2640	0.4199	0.4767
FT_percent	FT_percent	0.1729	0.2640	1.0000	0.3530	0.2652
PTS	PTS	0.1688	0.4199	0.3530	1.0000	0.8262
Racine_Salaire		0.3308	0.4767	0.2652	0.8262	1.0000

Age, W, FT_PERCENT et PTS ont une influence significative sur le salaire.

Analyse des résidus

- Les résidus ont-ils une espérance nulle ?

Hypothèse : H_0 : $E(\epsilon_x) = 0$

H_1 : $E(\epsilon_x) \neq 0$

t de Student	t	0	Pr > t	1.0000
--------------	---	---	---------	--------

La probabilité critique est égale à 1 donc on accepte H_0 .

- Les résidus suivent-ils une loi normale ?

Comme l'échantillon comprend **450 observations**, ce qui est **supérieur à 50**, nous avons choisi de tester la normalité des résidus à l'aide du test de **Kolmogorov-Smirnov**.

Hypothèse : H_0 : les résidus suivent une loi normale.

H_1 : les résidus ne suivent pas une loi normale.

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.99103	Pr < W	0.0079
Kolmogorov-Smirnov	D	0.038374	Pr > D	0.1043

La probabilité critique est **supérieure à 0.05** donc nous amène à **accepter H_0** , ce qui indique que les résidus **suivent** une loi normale.

- Sont-ils indépendants ?

Nous avons utilisé la statistique de **Durbin-Watson** pour tester l'indépendance des résidus. Selon les résultats, la statistique se situe entre **1,5 et 2,5**.

Hypothèse : H_0 : les résidus sont indépendants.


H_1 : les résidus sont dépendants.

Durbin-Watson D	2.055
------------------------	--------------

Le résultat est bien supérieur à 1.5 donc on accepte H_0 . Cela signifie que les résidus sont indépendants.

- Les résidus ont-ils une variance commune ?

Graphique des résidus



L'analyse graphique des résidus en fonction de plusieurs variables explicatives (Age, W, FT_percent et PTS) montre que la **variance des résidus est constante**.

Nous n'avons pas **de forme particulière** dans le graphique des résidus. Cela indique que les résidus ont une variance commune.

- Le modèle linéaire est-il approprié ?

Le modèle linéaire est globalement approprié. Il explique bien la variation du salaire ($R^2 = 73,40\%$) et les tests statistiques montrent que la relation entre le salaire et les variables explicatives (Age, W, FT_percent, PTS) est significative.

De plus, les hypothèses de normalité, d'indépendance et d'espérance nulle des résidus sont respectées.

Détection d'observations atypiques

- Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.

$$\text{Seuil : } \frac{2 \times (k+1)}{n} = \frac{2 \times 5}{450} = 0.0222$$

Les observations ayant une forte influence sur le calcul des paramètres du modèle sont celles dont les leviers h_i sont supérieurs à 0.0222. Voici les observations ayant des valeurs de résidus standardisés **supérieures à 0,0222**, comme présenté dans le tableau ci-dessous.

Observation (AGE-W-FT_percent-PTS)	h_i	Observation (AGE-W-FT_percent-PTS)	h_i
8	0,0402	249	0,0401
10	0,0233	272	0,023
44	0,037	289	0,0249
63	0,0235	293	0,0332
65	0,0424	298	0,0324
70	0,0234	360	0,039
89	0,04	365	0,0419
132	0,041	367	0,0239
147	0,0327	372	0,0397
153	0,0277	383	0,04
161	0,0391	399	0,0242
168	0,0404	405	0,0237
170	0,0417	408	0,0416
173	0,0267	430	0,0258
201	0,038	432	0,042
209	0,0403	433	0,0394
229	0,0361	444	0,0398

Les observations **8, 10, 44, 63, 65, 70, 89, 132, 147, 153, 161, 168, 170, 173, 201, 209, 229, 249, 272, 289, 293, 298, 360, 365, 367, 369, 372, 383, 399, 405, 408, 430, 432, 433 et 444** ont une forte influence sur le calcul de la pente de la droite et attirent de l'hyperplan des moindres carrés.

- Déterminer les points mal reconstitués par le modèle.

Pour déterminer les points mal reconstitués par le modèle, nous devons examiner les résidus standardisés ou studentisés (r_i). **Critère de sélection des points mal reconstitués** : Un résidu standardisé (r_i) dont la valeur **absolue** est **supérieure à 2** indique un point qui est mal reconstitué par le modèle. Voici les points ayant des valeurs de résidus standardisés **supérieures ou inférieures à 2**, comme présenté dans le tableau ci-dessous.

Observation (AGE-W-FT_percent-PTS)	ri	Observation (AGE-W-FT_percent-PTS)	ri
15	-2,643	151	-2,025
32	4,674	164	3,047
42	2,486	196	-2,767
59	-3,171	235	2,912
111	2,185	346	2,195
140	2,264	352	2,471
143	-2,172	385	2,373
144	2,089	447	2,289

Les points **15, 32, 42, 59, 111, 140, 143, 144, 151, 164, 196, 235, 346, 352, 385 et 447** sont mal reconstitués par le modèle. Ces points peuvent être des valeurs aberrantes, et il serait utile de les examiner de plus près pour comprendre pourquoi le modèle ne les a pas correctement ajustées.

Détection de la multicolinéarité

- Est-ce qu'il y a des variables qui sont corrélées 2 par 2 ?

Correlation						
Variable	Label	Age	W	FT_percent	PTS	Racine_Salaire
Age	Age	1.0000	0.2911	0.1729	0.1688	0.3308
W	W	0.2911	1.0000	0.2640	0.4199	0.4767
FT_percent	FT_percent	0.1729	0.2640	1.0000	0.3530	0.2652
PTS	PTS	0.1688	0.4199	0.3530	1.0000	0.8262
Racine_Salaire		0.3308	0.4767	0.2652	0.8262	1.0000

Seuil = 0,8 en valeur absolue

Les Age, W, FT_percent et PTS ne sont pas corrélés.

- Déterminer un ou plusieurs groupes de variables corrélées entre elles ?

Parameter Estimates							
Variable	Label	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	Intercept	1	-811.71650	295.39927	-2.75	0.0062	0
Age	Age	1	72.20728	10.43769	6.92	<.0001	1.10531
W	W	1	13.28407	3.10181	4.28	<.0001	1.30827
FT_percent	FT_percent	1	-6.63817	2.54705	-2.61	0.0095	1.17414
PTS	PTS	1	193.22435	7.03548	27.46	<.0001	1.31556

Les variables l'âge, le nombre de victoires(W), le pourcentage de réussite aux lancers francs (FT_PERCENT) et les points marqués (PTS) ont des vifs proches de 1 donc il n'y a pas de multicolinéarité entre ces 4 var.

Sixième partie : Prédire du salaire 5 joueurs réel à l'aide des modèles de régression linéaire

Player	Salaire	Racine	Mod Salaire - PTS	Mod Racine_Salaire - FP	Mod Salaire - Age PTS	Mod Racine_Salaire - Age FP	Mod Racine_Salaire - Age W FP% PTS
Cam Whitmore	3379080	1838,22741	14816366	2833	10907538	2338	2739
Dennis Smith	2087519	1444,8249	6283624	2665	6426320	2667	2101
Sasha Vezenkov	3700000	1923,53841	4487258	1683	5763682	1866	2015
Danuel House	4310250	2076,11416	2690891	1480	5634518	1880	2012
Alex Fudge	1862265	1364,64831	146038	1001	-2150474	721.3379	537.1644

Nous pouvons constater que les modèles sans changement de variable présentent un grand écart par rapport aux valeurs réelles. En revanche, les modèles avec cette transformation donnent des prédictions plus proches des valeurs réelles, comme démontré dans les analyses précédentes.

Les modèles avec plusieurs variables offrent de meilleures prédictions que ceux avec une seule variable. Parmi eux, le modèle multivariable utilisant Racine_Salaire en fonction d'Âge, W, FT_percent et PTS fournit les résultats les plus précis.

Cependant, il reste des observations particulières, comme celle du joueur Alex Fudge, dont le salaire prédit est très différent de la valeur réelle. Cela peut être dû à une observation atypique, c'est-à-dire une donnée qui s'éloigne significativement des tendances générales du modèle. Ce type d'observation peut influencer les résultats et nécessite une analyse plus approfondie pour comprendre son impact sur la fiabilité du modèle.

Modèle 1 variable : Salaire - PTS

Player	Salaire	Salaire - PTS	Intervalle	
Cam Whitmore	3379080	14816366	301902	29330830
Dennis Smith	2087519	6283624	-8232015	20799263
Sasha Vezenkov	3700000	4487258	-10031376	19005891
Danuel House	4310250	2690891	-11831691	17213473
Alex Fudge	1862265	146038	-14383770	14675846

Modèle 1 variable : Racine_Salaire - FP

Player	Racine_Salaire	Racine_Salaire - FP	Intervalle	
Cam Whitmore	1838,227407	2833	924.7847	4741
Dennis Smith	1444,824903	2665	757.1124	4573
Sasha Vezenkov	1923,538406	1683	-226.0965	3593
Danuel House	2076,114159	1480	-430.1736	3389
Alex Fudge	1364,648306	1001	-910.6808	2912

Modèle 2 variables : Salaire – Age et PTS

Player	Salaire	Salaire - Age PTS	Intervalle	
Cam Whitmore	3379080	10907538	-2965564	24780641
Dennis Smith	2087519	6426320	-7402278	20254918
Sasha Vezenkov	3700000	5763682	-8072585	19599948
Danuel House	4310250	5634518	-8226546	19495582
Alex Fudge	1862265	-2150474	-16008279	11707331

Modèle 2 variables : Racine_Salaire – Age et FP

Player	Racine_Salaire	Racine_Salaire - Age FP	Intervalle	
Cam Whitmore	1838,227407	2338	513.3867	4163
Dennis Smith	1444,824903	2667	847.9790	4487
Sasha Vezenkov	1923,538406	1866	44.3242	3687
Danuel House	2076,114159	1880	55.5707	3705
Alex Fudge	1364,648306	721.3379	-1103	2546

Modèle multiples variables : Racine_Salaire – Age et FP

Player	Racine_Salaire	Racine_Salaire - Age W FP% PTS	Intervalle	
Cam Whitmore	1838,227407	2739	949.5136	4528
Dennis Smith	1444,824903	2101	318.0942	3885
Sasha Vezenkov	1923,538406	2015	229.9970	3799
Danuel House	2076,114159	2012	229.9971	3800
Alex Fudge	1364,648306	537.1644	229.9972	2336

Septième partie : Suppression des observations mal reconstituées

Comme mentionné précédemment, le modèle à une seule variable sans changement de la variable salaire a rencontré le problème de la présence d'observations mal reconstituées. Ainsi, nous avons essayé de supprimer ces observations à plusieurs reprises dans le modèle "salaire en fonction de FGM", ce qui a amélioré la probabilité critique du test de Kolmogorov-Smirnov (elle est devenue supérieure à 0,05, ce qui est un meilleur résultat). Cependant, cette approche a nécessité la suppression d'un grand nombre d'observations, réduisant ainsi la taille de l'échantillon et donc la puissance statistique du modèle.

Voici un tableau récapitulatif des valeurs de R^2 , valeur F et probabilité critique du test de Kolmogorov-Smirnov lorsque nous avons progressivement éliminé les points mal reconstitués dans le modèle de régression linéaire simple "salaire en fonction de FGM".

Echantillon	r carre	valeur F	Pr > F	test Student	Durbin-Watson	Kolmogorov-Smirnov
450	0,6574	859,63	<.0001	0;1	1,99	<0,0100
427	0,7441	1230,1	<.0001	0;1	1,907	0,0238
397	0,7846	1438,54	<.0001	0;1	2,03	>0.15
377	0,8003	1502,58	<.0001	0;1	1,854	>0.15
362	0,8125	1559,62	<.0001	0;1	1,8	>0.15
351	0,8153	1540,92	<.0001	0;1	1,813	>0.15
344	0,8106	1463,28	<.0001	0;1	1,81	>0.15
341	0,8061	1409,43	<.0001	0;1	1,799	>0.15
337	0,796	1307,26	<.0001	0;1	1,795	>0.15

Nous avons également les problèmes liés à l'élimination des points mal reconstitués

- Réduire **la représentativité des données** et introduire un **biais**.
- Si trop de points sont supprimés, le modèle peut **trop bien s'adapter aux données restantes**, réduisant sa **capacité de généralisation**.
- Même après avoir supprimé les points mal reconstitués, le graphique des résidus a toujours **une forme d'entonnoir**, ce qui montre que la variance des erreurs reste instable.

Ainsi, nous concluons que la suppression des observations mal reconstituées ne résout pas les problèmes rencontrés. En revanche, la transformation de la variable salaire permet de les corriger, comme démontré dans les analyses précédentes.